Crisp-DM, Calidad del Dato

Ibermática digital

Proyectos IA – Crisp-dm Aplicado

Metodología de Desarrollo y Despliegue

Ibermática

AI
Artificial Intelligence / Advanced Analytics
Metodología de Desarrollo y Despliegue

Ibermática

Artificial Intelligence / Advanced Analytics

Metodología de Desarrollo y Despliegue

Ecosistema IA
- Múltiples Disciplinas
- Proyectos multidiciplinares.

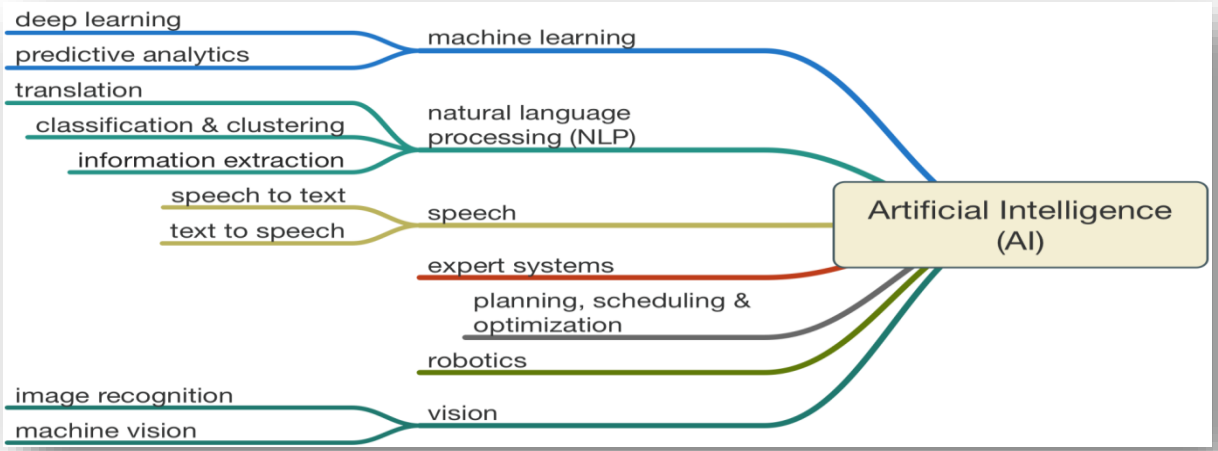

- Aceleradores para industrializar/automatizar la construcción de los casos de uso.

- *¿Existen?*
- ¿Cuándo se aplican?
- ¿Cómo se aplican?

¿Metodología sistemática vs Prueba y error?

Ibermática digital

Artificial Intelligence / Advanced Analytics

Metodología de Desarrollo y Despliegue

Ecosistema IA
- Múltiples Disciplinas
- Proyectos multidiciplinares.

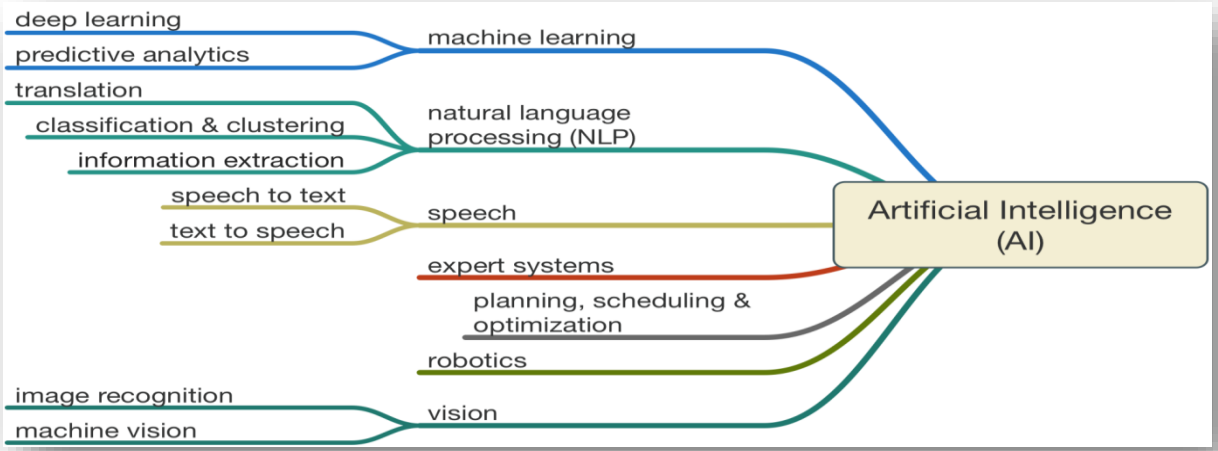

- Aceleradores para industrializar/automatizar la construcción de los casos de uso.

- ***¿Existen?***
- ¿Cuándo se aplican?
- ¿Cómo se aplican?

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

¿Existen?

-Métricas sobre Objetivos (Conocimiento del Negocio)

-Métricas sobre Recursos (Conocimiento de los Datos)

-Indicadores de avance en el Proyecto (Hitos de control analíticos)

-Métricas de Rendimiento (Modelado)

-Métricas de Evolución Productiva (Despliegue)

Aceleradores para industrializar/automatizar la construcción.

¿Existen?

-Métricas sobre Objetivos (Conocimiento del Negocio)

-Métricas sobre Recursos (Conocimiento de los Datos)

-Indicadores de avance en el Proyecto (Hitos de control analíticos)

-Métricas de Rendimiento (Modelado)

-Métricas de Evolución Productiva (Despliegue)

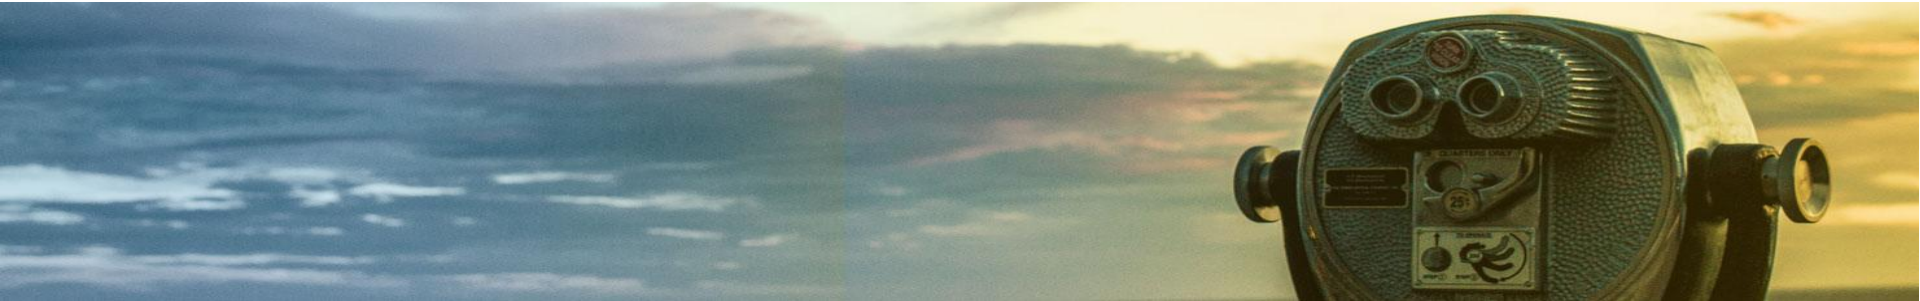

Métricas sobre Objetivos (Conocimiento del Negocio)

OBJETIVO DE NEGOCIO

"Definición completa del proyecto en una frase titular"

Es la base del Objetivo de Modelado.

OBJETIVOS

OBJETIVO DE MINERÍA

1) Existe campo de Minería.

- **Existen en los recursos el campo objetivo del análisis**
- **Proyecto Supervisado**

2) No existe campo de Minería:

- Hay que generarlo:
  - ***Calculado***:
    - De forma manual
    - De forma automática (Segmentación)
  - ***Inferirlo***: en base a reglas de negocio
  - ***Analizarlo***: Segmentación.

Decisión Clave:

-***Granularidad***: nivel mínimo de información analítica

-***Cadencia***: Tiempo en el que se "observan" la granularidad

- "PK" del tablón final
- Volumen de información
- Agregado en columnas

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

Objetivo de Modelado

Figure 2. Gartner Analytic Ascendancy Model

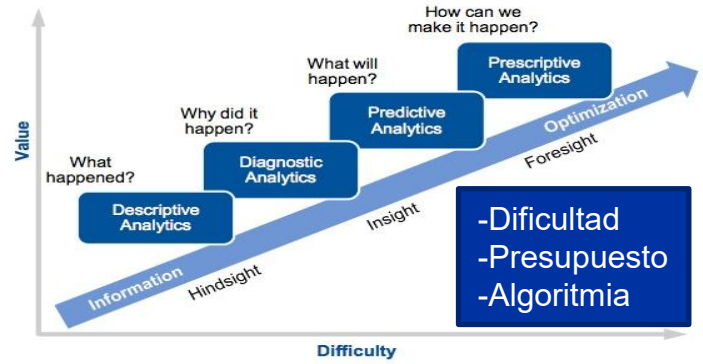

Source: Gartner (March 2012)

Respecto a las herramientas funcionales de análisis avanzado, existen 4 tipos de análisis:

Análisis Descriptivo: Muestra a los expertos las correlaciones entre indicadores, los patrones relacionados y las reglas que modelan dichos patrones. El modelado descriptivo trata de dar respuesta a las explicaciones de por qué se dan ciertos eventos con incidencias, y cuáles son las razones que explican dichos eventos.

Análisis Predictivo: En base a los modelos predictivos, el sistema podrá inferir eventos futuros de errores en las carrocerías en función de la situación actual del resto de sensores y sus correlaciones. Para ello se analizan las transacciones en tiempo real, en base a los modelos descriptivos anteriores, generándose eventos teóricos que indican cuándo se producirán incidencias futuras, su nivel de gravedad, y las razones de dichas incidencias

Análisis Proactivo: El desarrollo engloba toda la gestión del Mantenimiento Prescriptivo está basado en las detecciones de anomalías automáticas (DA).. La meta principal en la DA, es encontrar situaciones no usuales, explicando claramente cuáles son los indicadores que provocan dichas situaciones, y sus valores, de una forma automática y directa, en tiempo “real”.

Análisis Prescriptivo:
Escenarios y Simulación
Optimización y Recomendaciones

Ibermática digital

Objetivo de Modelado

Figure 2. Gartner Analytic Ascendancy Model

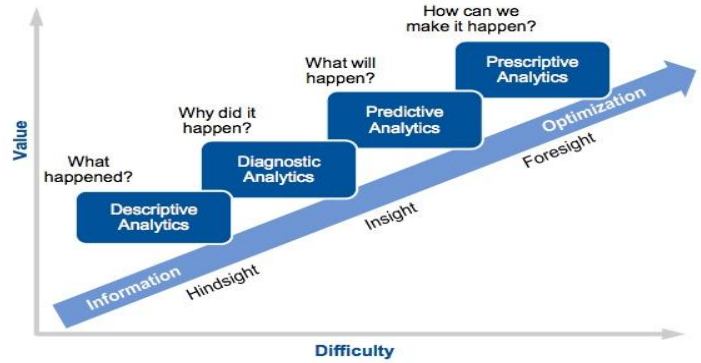

Source: Gartner (March 2012)

Análisis Proactivo:

•Algoritmos detección de anomalías automáticas (DA).
•Detección de Anomalías (LOF, COF. Encoders,…)

Respecto a las herramientas funcionales de análisis avanzado, existen 4 tipos de análisis:

Análisis Descriptivo:
-Sistemas de Reducción de Dimensiones (PCA)
-Clustering (Kmeans, SOM..)
-Árboles de Decisión y explicabilidad (XAI)

Análisis Predictivo:
-Redes Neuronales, SVM, Bayes, KNN, Convolucionales…
-Boosting (Xgboost, RandomForest, ..)
-Normalización de Series (DWT, Binning, …)
-Análisis de Series Temporales (LSTM, ARIMA, Hotl-Winters…)

Análisis Prescriptivo: Escenarios y Simulación, optimización y Recomendaciones:
-Algoritmos Genéticos (AG)
-Simulated annealing (SA)

Aceleradores para industrializar/automatizar la construcción

RETORNO DE MEJORA A OBTENER CON EL PROYECTO (ROI)

Beneficios / Reputación

Verdaderos Positivos (euros)

Verdaderos Negativos (euros)

Impacto en la Organización (euros)

Impacto en los Medios (euros)

Reducción de Costes

Falsos Positivos (euros)

Falsos Negativos (euros)

Impacto en la Organización (euros)

Mejora del Proceso

- Retorno Actual de Forma Manual
- Cuellos de Botella (euros)
- Reciclos (euros)
- Impacto en los Clientes/Usuarios (euros)

Métrica de error en el modelo (Optimización)

$$Error: \frac{1}{\sum w^{(i)}} \sum_{i=1}^{m_{dev}} w^{(i)} \mathcal{L}\{(\hat{y}^{(i)} \neq y^{(i)}\}$$

$$N_{metric}: \begin{cases} 1 & Optimizing\ metric \\ N_{metric} - 1 & Satisficing\ metric \end{cases}$$

Métrica de Rendimiento (Performance)

- Métrica de Optimización (Accuracy)
- Métricas de Satisfacción (Tiempo ejecución, hard necesario, XAI, …)

Influye directamente en:

- Calidad de Datos Mínima requerida
- La potencia predictiva mínima del modelo (error Bayes)
- El presupuesto del proyecto vs ROI
- Las rutas de ajustes al modelo en función de la potencia predictiva (Ortogonalización de modelos)

Aceleradores para industrializar/automatizar la construcción.

Resumen Métricas sobre Objetivos

-Métricas sobre Objetivos (Conocimiento del Negocio)
- Objetivo de Negocio
- Objetivo de Minería
- Granularidad
- Cadencia
- Objetivo de Modelado
- ROI

•Tipología de Proyecto
•PK (claves) del tablón final
•Volumen de información final
•Agregado en columnas
•Dificultad Algorítmica
•Calidad Dato Requerida
•Performance Requerido
•Beneficio Requerido
•Presupuesto Estimado en IA.

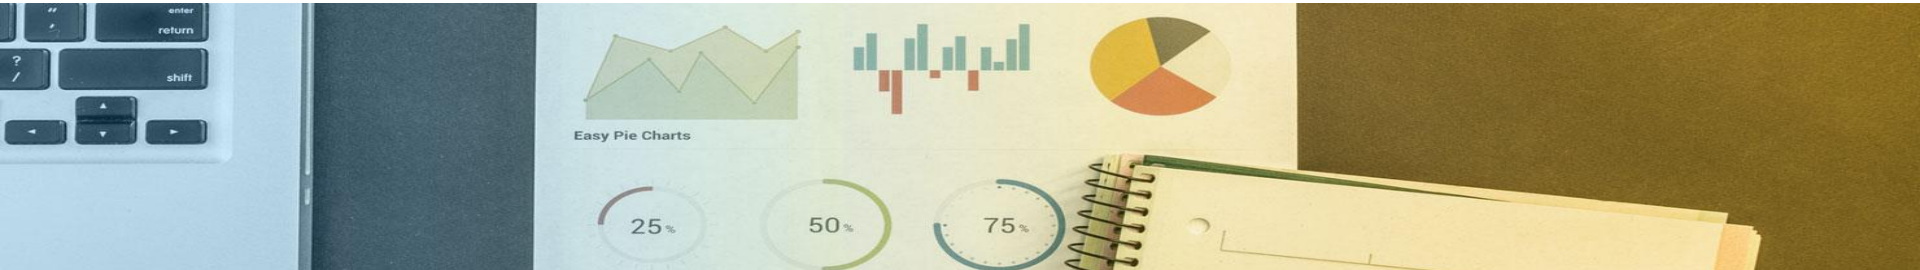

Aceleradores para industrializar/automatizar la construcción.

¿Existen?

-Métricas sobre Objetivos (Conocimiento del Negocio)

-Métricas sobre Recursos (Conocimiento de los Datos)

-Indicadores de avance en el Proyecto (Hitos de control analíticos)

-Métricas de Rendimiento (Modelado)

-Métricas de Evolución Productiva (Despliegue)

Aceleradores para industrializar/automatizar la construcción.

Métricas sobre Recursos: Datos

Volumen

Datos Internos

- Estructurados → IA Clásica / IA Distribuida Clusters (ej. Spark mlib)
- Semi-Estructurados → IA Clásica / IA Distribuida en Grafos (ej. Spark graph)
- No Estructurados → IA Clásica / IA Paralelizada (ej. GPU – Tensor flow)

Datos Externos

- Datos de Eventos
- Datos Meteorológicos
- …

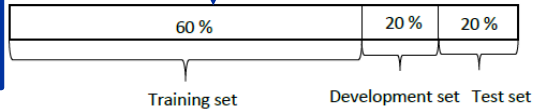

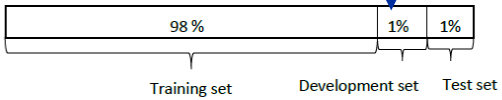

- ***Necesidades de Hard***
- ***Necesidades de Plataforma Analítica***
- ***Dimensionamiento de Entornos de Trabajo***
- ***Métricas de generación de subconjuntos de entrenamiento/desarrollo y testeo***

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

Métricas sobre Recursos: Equipo

Proveedor

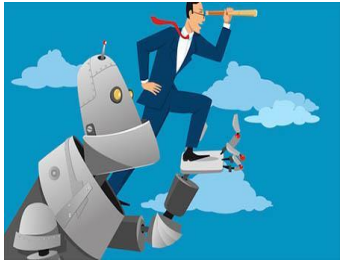

Cliente

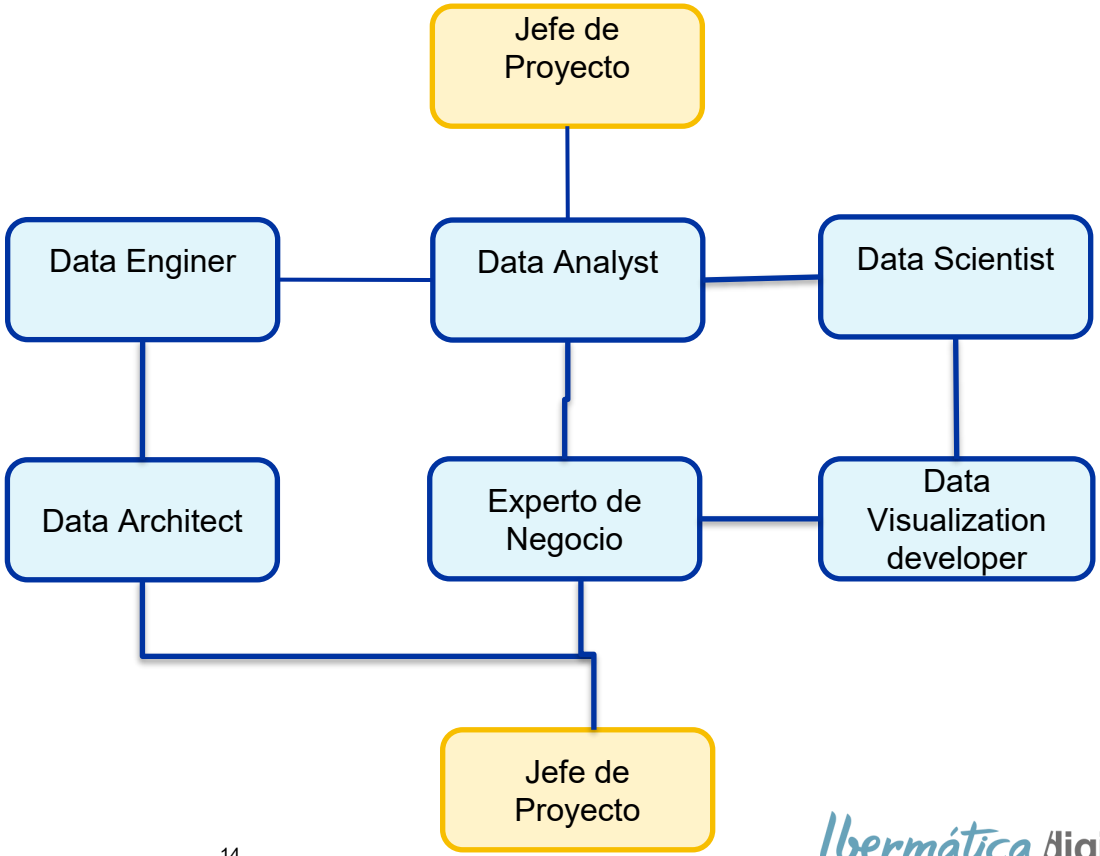

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

Resumen Métricas sobre Recursos

-Métricas sobre Recursos
- Catálogo de Datos Internos
- Catálogo de Datos Externos
- Naturaleza de los Datos
- Volumen de los Datos

•Necesidades de Hard
•Necesidades de Plataforma Analítica
•Dimensionamiento de Entornos de Trabajo
•Métricas de generación de subconjuntos de entrenamiento/desarrollo y testeo
•Dimensionamiento Equipo de Trabajo

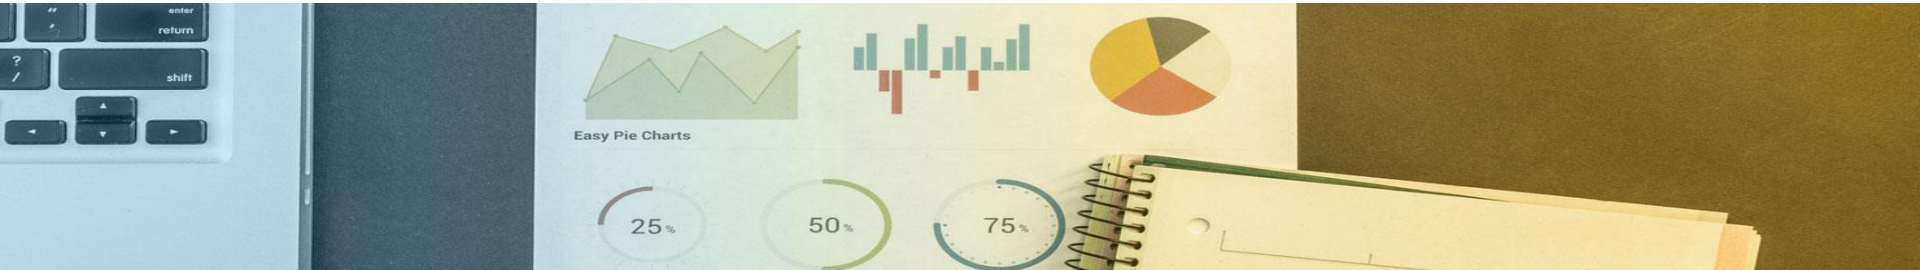

Aceleradores para industrializar/automatizar la construcción.

¿Existen?

-Métricas sobre Objetivos (Conocimiento del Negocio)

-Métricas sobre Recursos (Conocimiento de los Datos)

-Indicadores de avance en el Proyecto (Hitos de control analíticos)

-Métricas de Rendimiento (Modelado)

-Métricas de Evolución Productiva (Despliegue)

Indicadores de Avance sobre el Proyecto.

Análisis de la Calidad de Datos

La mala calidad de los datos en origen es un problema habitual al cual se enfrentan los sistemas analíticos. Los contextos en los que no existe un método de Gobierno de datos establecido pueden agravar este tipo de situaciones generando multitud de "**falsos positivos**" en las predicciones resultantes a partir del modelado.

En este sentido, lo importante y prioritario es tener un punto de partida, una serie de métricas que permitan identificar el estado actual de los datos. Para ello, es básico realizar una auditoría inicial o perfilamiento de los datos, con el objetivo de averiguar en qué estado se encuentran éstos y a partir de ahí, detectar qué se debe corregir y a su vez determinar parámetros de control que ayuden a medir el avance en los procesos de calidad.

Estos parámetros son conocidos como las ***seis dimensiones*** de calidad de datos y son consideradas como los puntos clave que debe de cubrir la calidad de los datos para asegurar nuestros procesos de limpieza y calidad.

Completitud	¿Qué datos faltan, no están rellenos adecuadamente o no se usan?
Conformidad	¿Qué datos se guardan en un formato no estándar?
Consistencia	¿Qué valores de los datos generan conflictos en la información?
Exactitud	¿Qué datos son incorrectos o fuera de validez?
Duplicidad	¿Qué datos o atributos están repetidos?
Integridad	¿Qué datos no están referenciados?

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

Indicadores de Avance sobre el Proyecto.

Potencia Estadística

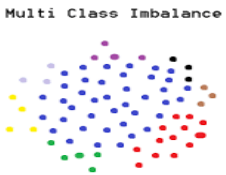

Balanceado de Muestras (Sesgo)

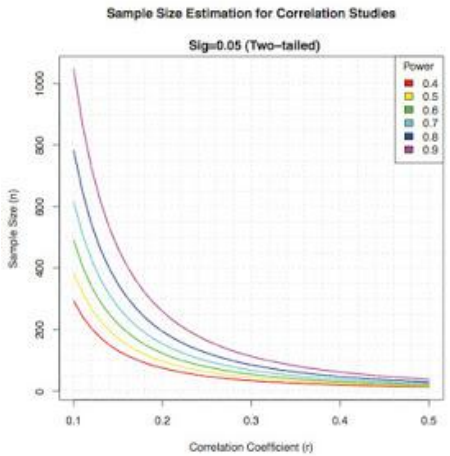

Figure 10.3 Sample size curves for detecting a significant correlation at various power levels

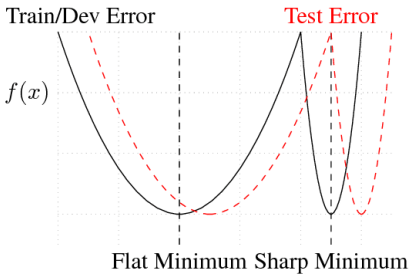

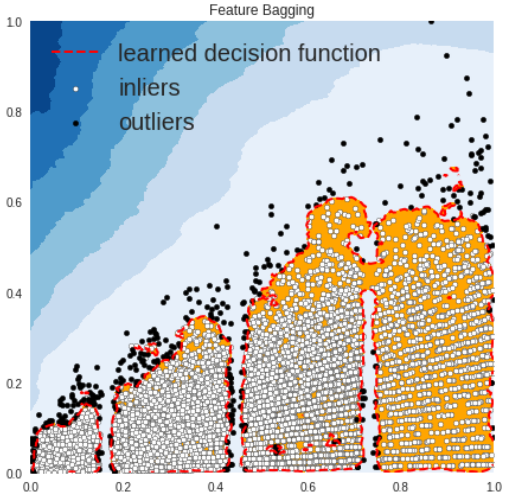

Tamaño

Distribución de los subconjuntos de entrenamiento

“Outliers” Multivariable

Subconjunto de datos “gold standard”

Ibermática digital

Resumen Indicadores de Avance sobre el Proyecto.

Potencia Predictiva Inicial y Profundidad de Históricos

Primera prueba con algoritmos de fuerza bruta (o iteración simple por múltiples algoritmos), en base a una validación cruzada para determinar la Potencia Predictiva Inicial y la Profundidad de Históricos objetiva.

Potencia Predictiva Inicial > (1-Error Bayes) * 0,85

PerformanceVector

```
PerformanceVector:
root_mean_squared_error: 3.884 +/- 0.980 (mikro: 4.006 +/- 0.000)
absolute_error: 3.050 +/- 0.845 (mikro: 3.050 +/- 2.597)
squared_error: 16.048 +/- 10.692 (mikro: 16.048 +/- 32.105)
correlation: 0.852 +/- 0.139 (mikro: 0.857)
squared_correlation: 0.745 +/- 0.161 (mikro: 0.735)
prediction_average: 12.456 +/- 2.225 (mikro: 12.456 +/- 7.630)
spearman_rho: 0.801 +/- 0.134 (mikro: 129.765)
kendall_tau: 0.633 +/- 0.113 (mikro: 102.554)
```

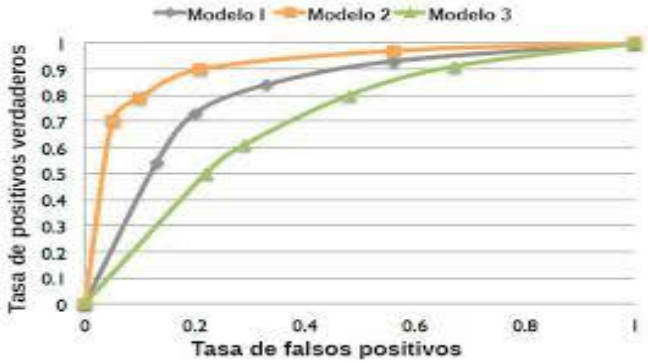

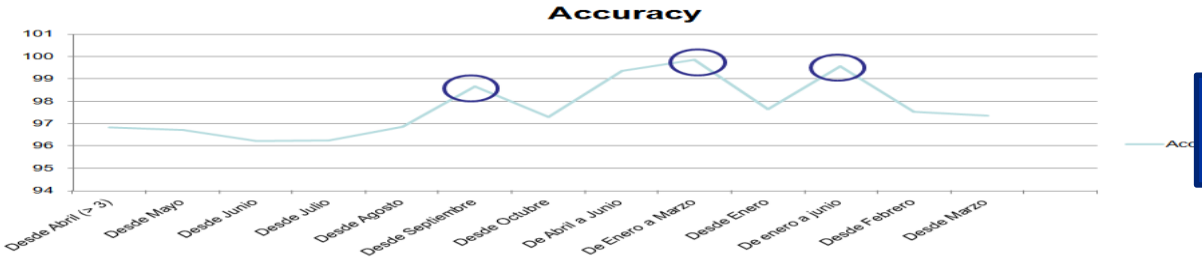

Profundidad histórica objetiva (<> 25 meses estándar)

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

Indicadores de Avance sobre el Proyecto.

-Indicadores de Avance sobre el Proyecto.
- Calidad de los Datos
- Potencia Estadística
- Potencia Predictiva

•Informe de Calidad de los Datos
•Performance de Calidad de los Datos
•Necesidades de corrección en datos iniciales (normalización, limpieza, estandarización)
•Balanceado de Objetivo de Minería (análisis del sesgo).
•“Gold estándar” inicial de datos
•Profundidad de Histórico objetiva
•Fin de Fase I. Decisión sobre seguir o no el proyecto.

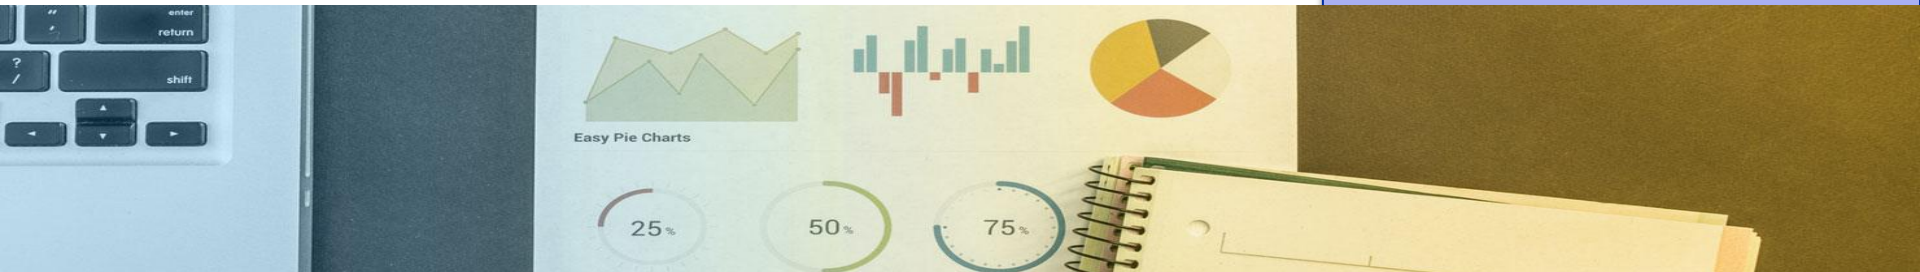

Aceleradores para industrializar/automatizar la construcción.

¿Existen?

-Métricas sobre Objetivos (Conocimiento del Negocio)

-Métricas sobre Recursos (Conocimiento de los Datos)

-Indicadores de avance en el Proyecto (Hitos de control analíticos)

-Métricas de Rendimiento (Modelado)

-Métricas de Evolución Productiva (Despliegue)

Aceleradores para industrializar/automatizar la construcción.

Métricas de Rendimiento (Modelado): Función de evaluación del modelo

- Métrica de Optimización (Accuracy)
- Métricas de Satisfacción (Tiempo ejecución, hard necesario, XAI, …)

$$Error: \frac{1}{\sum w^{(i)}} \sum_{i=1}^{m_{dev}} w^{(i)} \mathcal{L}\{(\hat{y}^{(i)} \neq y^{(i)}\}$$

$$N_{metric}: \begin{cases} 1 & \textit{Optimizing metric} \\ N_{metric} - 1 & \textit{Satisficing metric} \end{cases}$$

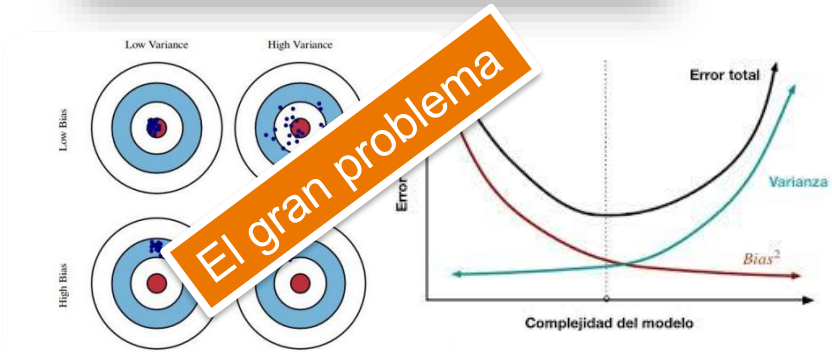

Naturaleza del Objetivo de Minería

- *Davies–Bouldin index*
- *Gini Index*

- *Matriz de confusión o error*
- *Precisión*
- *Recall o sensibilidad o TPR (Tasa positiva real)*
- *Especificidad o TNR (Tasa negativa real)*
- *F1-Score*
- *Área bajo la curva de funcionamiento del receptor (ROC) (AUC)*
- *Pérdida logarítmica*
- *Cohen's Kappa*

- *Error Medio Absoluto (MAE)*
- *Error Cuadrático Medio (MSE, RMSE)*

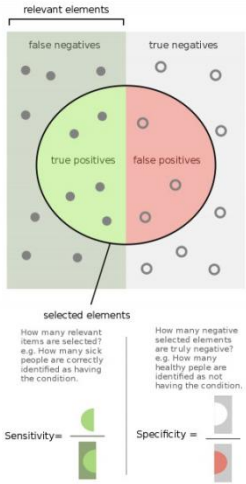

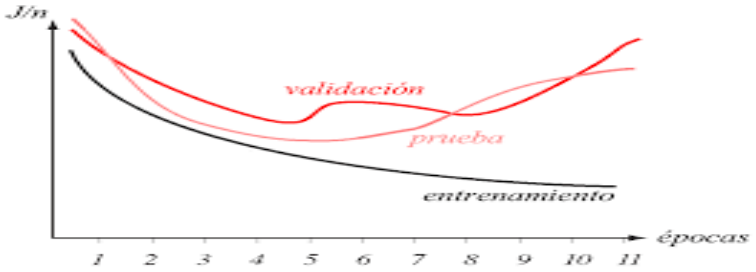

digital

Aceleradores para industrializar/automatizar la construcción.

Métricas de Rendimiento (Modelado): Ajuste en función del Problema

Bayes Error (Rendimiento Teórico)

Problema de “Sesgo” → Procedimiento de ajuste de sesgo (bias)

Error en entrenamiento (Train set)

Problema de Varianza → Procedimiento de ajuste de Varianza

Error unitario en desarrollo (Train-Dev set)

Incompatibilidad de distribuciones → Procedimiento de ajuste de “mismacth”

Error en desarrollo (Dev set)

Problema de sobreajuste → Procedimiento de “overfitting”

Error en Producción (Test set)

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

¿Existen?

-Métricas sobre Objetivos (Conocimiento del Negocio)

-Métricas sobre Recursos (Conocimiento de los Datos)

-Indicadores de avance en el Proyecto (Hitos de control analíticos)

-Métricas de Rendimiento (Modelado)

-Métricas de Evolución Productiva (Despliegue)

Aceleradores para industrializar/automatizar la construcción.

Métricas de Evolución Productiva

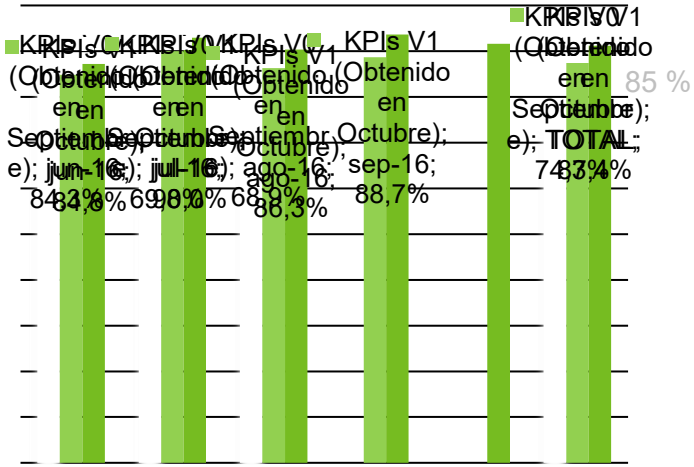

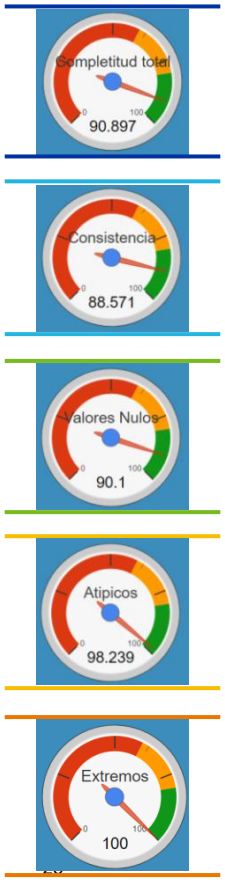

Evolución de la Calidad del Dato

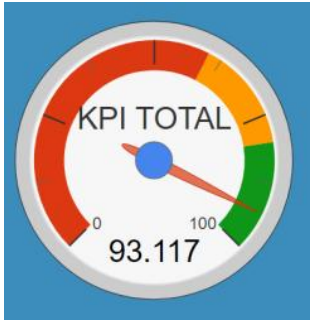

- Evolución del Rendimiento durante toda la vida del Sistema
- Control sobre el Rendimiento: Mantenimiento de los Modelos.

INSTITUTO IBERMÁTICA DE INNOVACIÓN
Ibermática digital

Artificial Intelligence / Advanced Analytics

Metodología de Desarrollo y Despliegue

Ecosistema IA
- Múltiples Disciplinas
- Proyectos multidiciplinares.

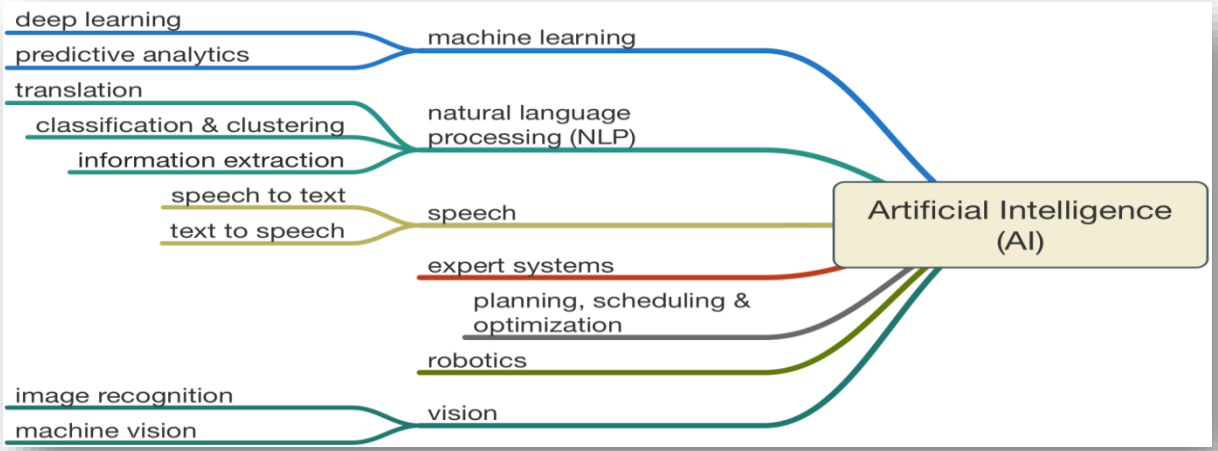

- Aceleradores para industrializar/automatizar la construcción de los casos de uso.

- ¿Existen?
- ***¿Cuándo se aplican?***
- ¿Cómo se aplican?

Ibermática digital

Aceleradores para industrializar/automatizar la construcción.

¿Cuándo se aplican?

CRISP-DM es una metodología de desarrollo de sistemas de explotación de información que permite el **aseguramiento de la calidad técnica**. Los datos deben ser extraídos, depurados y preparados para su uso e interpretación. Este método se divide en 6 fases: conocimiento del negocio, conocimiento de los datos, preparación de los datos, modelización, evaluación y desarrollo.

CONOCIMIENTO DEL NEGOCIO

Determinar objetivos de negocio
Antecedentes
Objetivos de negocio
Criterios de éxito de negocio

Evaluación de la situación
Inventario de recursos
Requisitos, supuestos y restricciones
Riesgos y contingencias
Terminología
Costes y beneficios

Determinar los objetivos de Data Mining
Objetivos de Data Mining
Criterios de éxito de Data Mining

Elaborar el plan de proyecto
Plan de proyecto
Evaluación inicial de herramientas y técnicas

CONOCIMIENTO DE LOS DATOS

Recoger los datos iniciales
Informe de recogida de datos inicial

Describir los datos
Informe de descripción de datos

Explorar los datos
Informe de exploración de datos

Verificar la calidad de los datos
Informe de calidad de los datos

Control 1
Calidad
Potencia

PREPARACIÓN DE LOS DATOS

Conjunto de datos
Descripción del conjunto de datos

Seleccionar los datos
Justificación para la inclusión / exclusión

Limpiar los datos
Informe de la limpieza de datos

Construir los datos
Atributos derivados
Informes generados

Datos integrados
Datos combinados

Formatear los datos
Datos reformateados

MODELADO

Seleccionar la técnica de modelado
Técnica de modelado
Supuestos de modelado

Generar el diseño de prueba
Diseño de prueba

Construir el modelo
Configuración de parámetros
Modelos
Descripción del modelo

Evaluar el modelo
Evaluación del modelo
Configuración de parámetros revisada

Control 2
Procedimientos de ajuste de rendimientos

EVALUACIÓN

Evaluar los resultados
Evaluación de los resultados del Data Mining
Criterios de éxito de negocio

Revisar el proceso
Revisión del proceso

Determinar próximos pasos
Lista de posibles acciones
Decisión

Control 3
Evaluación de Modelos Test

DESPLIEGUE

Planear el desarrollo
Plan de despliegue

Planear la monitorización y el mantenimiento
Plan de monitorización y mantenimiento

Elaborar el informe final
Informe final
Presentación final

Revisar el proyecto
Documentación de experiencias

Control 4
Evaluación de Calidad y Potencia

Variables Cuantificación Presupuesto

Ibermática digital

METODOLOGÍA ESPECÍFICA DE IMPLEMENTACION

CRISP-DM: ANÁLISIS DE CALIDAD DEL DATO Y POTENCIA PREDICTIVA

CRISP-DM es una metodología de desarrollo de sistemas de explotación de información que permite el **aseguramiento de la calidad técnica**. Los datos deben ser extraídos, depurados y preparados para su uso e interpretación. Este método se divide en 6 fases: conocimiento del negocio, conocimiento de los datos, preparación de los datos, modelización, evaluación y desarrollo.

CONOCIMIENTO DEL NEGOCIO

Determinar objetivos de negocio
Antecedentes
Objetivos de negocio
Criterios de éxito de negocio

Evaluación de la situación
Inventario de recursos
Requisitos, supuestos y restricciones
Riesgos y contingencias
Terminología
Costes y beneficios

Determinar los objetivos de Data Mining
Objetivos de Data Mining
Criterios de éxito de Data Mining

Elaborar el plan de proyecto
Plan de proyecto
Evaluación inicial de herramientas y técnicas

CONOCIMIENTO DE LOS DATOS

Recoger los datos iniciales
Informe de recogida de datos inicial

Describir los datos
Informe de descripción de datos

Explorar los datos
Informe de exploración de datos

Verificar la calidad de los datos
Informe de calidad de los datos

PREPARACIÓN DE LOS DATOS

Conjunto de datos
Descripción del conjunto de datos

Seleccionar los datos
Justificación para la inclusión / exclusión

Limpiar los datos
Informe de la limpieza de datos

Construir los datos
Atributos derivados
Informes generados

Datos integrados
Datos combinados

Formatear los datos
Datos reformateados

MODELADO

Seleccionar la técnica de modelado
Técnica de modelado
Supuestos de modelado

Generar el diseño de prueba
Diseño de prueba

Construir el modelo
Configuración de parámetros
Modelos
Descripción del modelo

Evaluar el modelo
Evaluación del modelo
Configuración de parámetros revisada

EVALUACIÓN

Evaluar los resultados
Evaluación de los resultados del Data Mining
Criterios de éxito de negocio

Revisar el proceso
Revisión del proceso

Determinar próximos pasos
Lista de posibles acciones
Decisión

DESPLIEGUE

Planear el desarrollo
Plan de despliegue

Planear la monitorización y el mantenimiento
Plan de monitorización y mantenimiento

Elaborar el informe final
Informe final
Presentación final

Revisar el proyecto
Documentación de experiencias

CONOCIMIENTO DEL NEGOCIO	CONOCIMIENTO DE LOS DATOS	PREPARACIÓN DE LOS DATOS	MODELADO	EVALUACIÓN	DESPLIEGUE
40%		20%	20%	10%	10%

Ibermática digital

¡Gracias!