CRISP-DM — FASE 3

Preparacion de los Datos

Deteccion Automatica de Transacciones Fraudulentas

Dataset:	Credit Card Fraud Detection (Kaggle — MLG-ULB)
Registros totales:	283.726 transacciones reales
Fraudes:	473 (0.167%)
Metodologia:	CRISP-DM — Fase 3
Version:	1.0 — Marzo 2026

Introduccion

Contexto CRISP-DM — Fase 3

La fase de Preparación de los Datos comprende todas las actividades para construir el conjunto final de datos que será utilizado en la fase de Modelado. Los resultados presentados en este documento corresponden a la ejecución del pipeline sobre el dataset real Credit Card Fraud Detection de Kaggle (MLG-ULB), con 283.726 transacciones reales.

Paso	Tarea	Resultado
3.1	Selección y limpieza de variables	0 nulos. 1081 duplicados eliminados. 18.802 outliers en Amount identificados.
3.2	Feature Engineering	5 nuevas variables: Amount_log (skew 16.98->0.16), Hour_sin, Hour_cos, Is_Night, Amount_zscore
3.3	Selección final de features	33 variables predictoras. Time y Amount originales descartados.
3.4	Partición estratificada	Train 170.235 / Dev 56.745 / Test 56.746 — proporcion fraudes preservada
3.5	Normalización	RobustScaler ajustado sobre train. Dev y test transformados sin data leakage.
3.6	Balanceo de clases	SMOTE (169.951 sinteticos), Undersampling (284 por clase), class_weight

3.1 Seleccion y Limpieza de Variables

Valores Nulos

El dataset real no contiene valores nulos en ninguna de sus 31 columnas, confirmando la alta calidad del dato.

```
# Verificacion de valores nulos
df.isnull().sum().sum()   # -> 0
```

Duplicados

Se detectaron y eliminaron 1081 filas duplicadas, correspondientes al 0.38% del total de registros. Probablemente reintentos de autorizacion registrados multiples veces por el sistema bancario.

```
# Deteccion y eliminacion de duplicados
n_dup = df.duplicated().sum()   # -> 1081
df = df.drop_duplicates()
# Shape tras limpieza: (283.726, 31)
```

Outliers en Amount

Se identificaron 18.802 transacciones con Amount superior al umbral IQR extendido (Q3 + 3*IQR). Representan el 6.63% del total y se conservan porque pueden corresponder a transacciones legitimas de alto valor o fraudes de gran cuantia. El RobustScaler los controlara en la fase de normalizacion.

```
# Deteccion outliers en Amount (IQR x3)
Q1, Q3 = df["Amount"].quantile([0.25, 0.75])
upper_bound = Q3 + 3*(Q3-Q1)
n_outliers = (df["Amount"] > upper_bound).sum()   # -> 18.802

# Decision: CONSERVAR. Importe maximo real: 25.691,16 EUR
# Controlados mediante RobustScaler en la fase de normalizacion.
```

Metrica	Valor Real (Dataset Kaggle)
Registros totales	283.726
Valores nulos	0 — Dataset completo al 100%
Filas duplicadas eliminadas	1081 (0.38% del total)
Amount media	88.47 EUR
Amount desv. tipica	250.40 EUR
Amount maximo	25.691,16 EUR
Outliers Amount (Q3 + 3*IQR)	18.802 (6.63%) — Conservados

3.2 Feature Engineering

Objetivo

Maximizar la información disponible para los modelos creando variables derivadas que capturen patrones no expresados directamente: la distribución del importe de la transacción y el comportamiento temporal cíclico. Los resultados se han validado sobre el dataset real con 283.726 transacciones.

Transformación Logarítmica de Amount

El dataset real presenta una asimetría extremadamente alta en Amount (skewness = 16.98), muy superior a lo esperado. Esto se debe a la presencia de 18.802 valores extremos concentrados en los percentiles altos. La transformación log1p reduce drásticamente esta asimetría hasta 0.16, casi perfectamente simétrica.

```
# Transformacion logaritmica
df["Amount_log"] = np.log1p(df["Amount"])

# Resultado sobre datos reales:
# Skewness Amount original: 16.98  (asimetria extrema)
# Skewness Amount_log:       0.16  (reduccion del 99%)
```

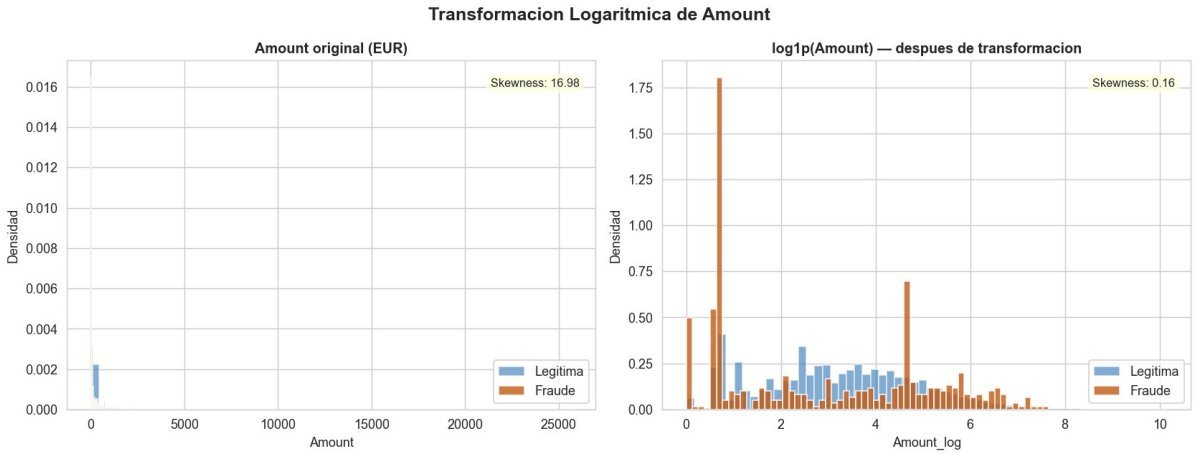

Figura 1: Distribucion de Amount antes (skew=16.98) y despues (skew=0.16) de la transformacion log1p por clase

La figura confirma que los fraudes (naranja) presentan una distribución bimodal en Amount_log con picos en valores bajos (~1) y medios (~4.5), mientras que las transacciones legitimas muestran una distribución más uniforme. Esta diferencia es un patrón discriminante útil para los modelos.

Variables Ciclicas de Tiempo

Las transacciones fraudulentas muestran un patrón temporal diferente al de las legítimas: dos picos claros a las 2-3h y al mediodía, mientras las legítimas siguen el ciclo normal de actividad comercial (8h-22h). La codificación cíclica captura este patrón sin discontinuidades artificiales.

```
# Hora del dia y codificacion ciclica
df["Hour"]     = (df["Time"] / 3600) % 24
df["Hour_sin"] = np.sin(2 * np.pi * df["Hour"] / 24)
```

```
df["Hour_cos"] = np.cos(2 * np.pi * df["Hour"] / 24)
df["Is_Night"] = ((df["Hour"] >= 0) & (df["Hour"] < 6)).astype(int)
```

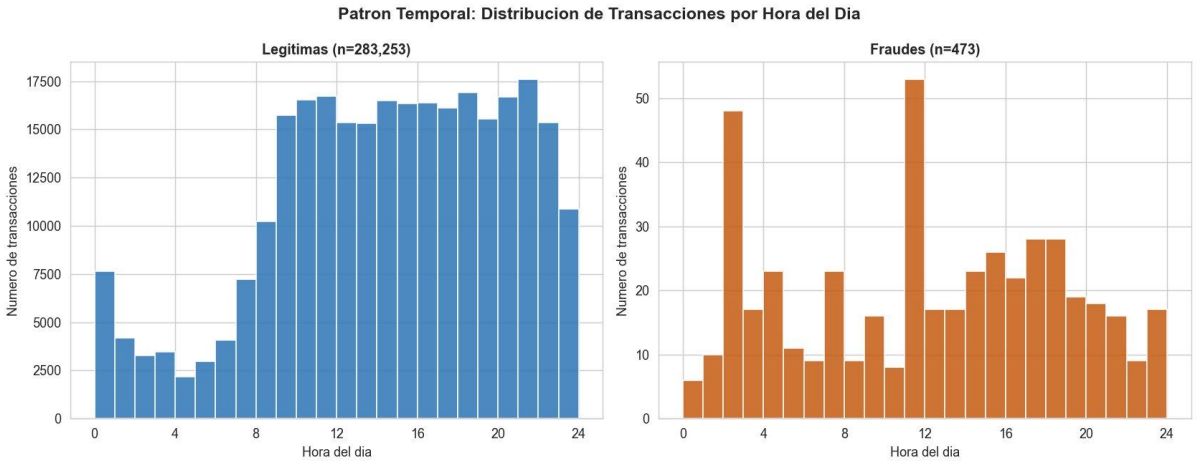

Figura 2: Patron temporal real — las legitimas (n=283.253) siguen el ciclo comercial; los fraudes (n=473) se concentran en horas nocturnas y al mediodia

Resumen de Variables Creadas y Eliminadas

Variable	Tipo	Resultado Real	Accion
Amount_log	Nueva	Skew: 16.98 -> 0.16 (reduccion 99%)	Incluir
Hour_sin	Nueva	Captura ciclo diario. Fraudes: picos 2-3h y 12h	Incluir
Hour_cos	Nueva	Componente ciclica complementaria	Incluir
Is_Night	Nueva	Fraudes sobrerrepresentados en horas 0-6h	Incluir
Amount_zscore	Nueva	Zscore de Amount. Ref. de desviacion respecto media	Incluir
Time	Original	Sustituida por variables ciclicas	Eliminar
Amount	Original	Sustituida por Amount_log y Amount_zscore	Eliminar

3.3 Seleccion Final de Features

El tablón final contiene 33 variables predictoras: las 28 componentes PCA (V1-V28) mas 5 variables nuevas. Time y Amount originales son descartados.

Grupo	Variables	N
Componentes PCA	V1, V2, V3, ..., V28 (variables anonimizadas del dataset original)	28
Importe transformado	Amount_log, Amount_zscore	2
Temporales ciclicas	Hour_sin, Hour_cos, Is_Night	3
TOTAL FEATURES	—	33

Correlacion con la Variable Objetivo — Resultados Reales

En el dataset real, V17 es la variable mayor correlación negativa con Class (r=-0.313), seguida de V14 (r=-0.293) y V12 (r=-0.251). En positivo, V11 lidera con r=0.149. Cabe destacar que Is_Night muestra correlacion positiva (r=0.023) con fraude, confirmando el patrón temporal detectado en el análisis temporal.

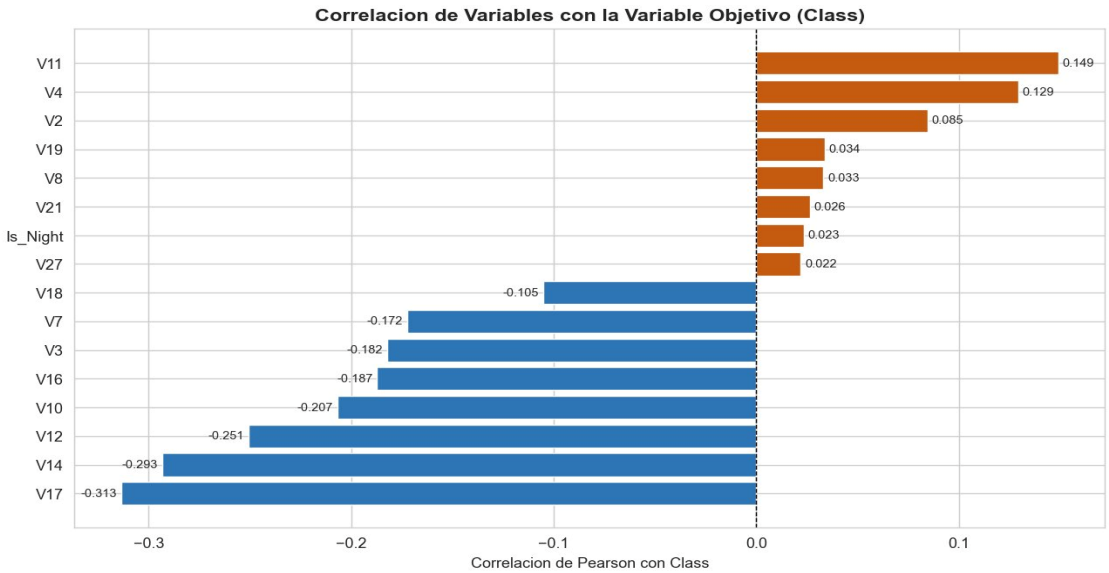

Figura 3: Correlacion de Pearson real con Class — V17 (-0.313), V14 (-0.293) y V12 (-0.251) son las mas discriminantes

Variable	Correlacion Real	Direccion	Interpretacion
V17	-0.313	Negativa fuerte	Variable más discriminante del dataset. Valores muy bajos = fraude.
V14	-0.293	Negativa fuerte	Segunda variable más discriminante. Patron de anomalía transaccional.
V12	-0.251	Negativa fuerte	Comportamiento inusual del titular de la tarjeta.
V10	-0.207	Negativa media	Relacionada con el perfil de gasto del cliente.
V16	-0.187	Negativa media	Indicador de patrón de uso atípico.

Variable	Correlacion Real	Direccion	Interpretacion
V11	0.149	Positiva fuerte	Unica componente con correlacion positiva alta con fraude.
V4	0.129	Positiva fuerte	Segunda componente positiva mas discriminante.
Is_Night	0.023	Positiva baja	Los fraudes ocurren ligeramente mas en horario nocturno.

Distribucion de Variables Discriminantes por Clase

Los boxplots sobre el dataset real confirman separacion clara entre clases en las 6 variables principales. Destaca V14: su mediana en fraude (~-8) esta totalmente separada de su mediana en transacciones legitimas (~0), lo que la convierte en un predictor altamente fiable.

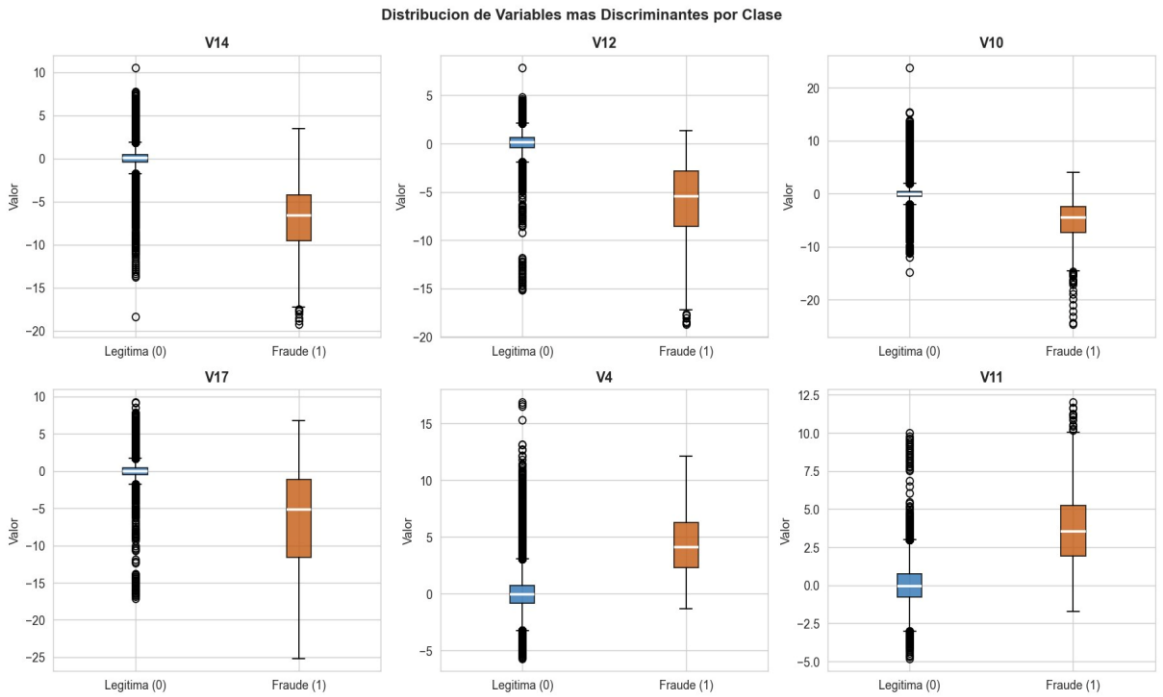

Figura 4: Boxplots reales de las 6 variables mas discriminantes. La separacion entre clases valida su alto poder predictivo.

3.4 Particion Estratificada del Dataset

Particion Estratificada sobre 283.726 transacciones reales

Con solo 473 fraudes (0.167%%), la particion estratificada es imprescindible. Los resultados muestran que la proporcion se preserva exactamente en los tres conjuntos: Train 0.167%, Dev 0.166%, Test 0.167%.

```
from sklearn.model_selection import train_test_split

# Paso 1: separar test (20%)
X_train_full, X_test, y_train_full, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42)

# Paso 2: separar dev (25% del 80% = 20% total)
X_train, X_dev, y_train, y_dev = train_test_split(
    X_train_full, y_train_full, test_size=0.25,
    stratify=y_train_full, random_state=42)
```

Conjunto	Proporcion	Filas Reales	Fraudes Reales	% Fraudes
Training set	60%	170.235	284	0.167%
Development set	20%	56.745	94	0.166%
Test set	20%	56.746	95	0.167%
TOTAL	100%	283.726	473	0.167%

3.5 Normalizacion con RobustScaler

Se utiliza RobustScaler (mediana + IQR) en lugar de StandardScaler porque el dataset real contiene 18.802 valores extremos en Amount (hasta 25.691,16 EUR). StandardScaler se veria distorsionado; RobustScaler es inmune a estos extremos.

Regla Anti-Data-Leakage

El scaler se ajusta UNICAMENTE sobre el training set (170.235 filas). Dev y test se transforman con los parametros del train. Utilizar fit_transform sobre dev o test introduciria informacion futura en el modelo (data leakage).

```
from sklearn.preprocessing import RobustScaler

scaler = RobustScaler()

# Ajuste SOLO sobre train (170.235 filas)
X_train_scaled = scaler.fit_transform(X_train)

# Transform de dev y test — SIN fit
X_dev_scaled  = scaler.transform(X_dev)
X_test_scaled = scaler.transform(X_test)

# Persistir para inferencia en produccion:
# import joblib; joblib.dump(scaler, "scaler.pkl")
```

Parametro	StandardScaler	RobustScaler	Por que RobustScaler en este dataset
Centrado	Media	Mediana	La media de Amount (88 EUR) esta distorsionada por los 18.802 outliers
Escala	Desv. Tipica	IQR (Q3-Q1)	La desv. tipica de Amount (250 EUR) es 3x la media — altamente sensible a outliers
Robustez outliers	Baja	Alta	Con Amount max=25.691,16 EUR, StandardScaler comprimia el rango util

3.6 Tecnicas de Balanceo de Clases

Desbalance real del dataset

Training set real: 169.951 transacciones legitimas vs 284 fraudes. Ratio: 598:1. Un clasificador naive que prediga siempre "Legitima" alcanzaria accuracy del 99.83% sin detectar ni un solo fraude.

SMOTE — Synthetic Minority Oversampling Technique

Genera 169.667 instancias sinteticas de fraude por interpolacion entre muestras reales y sus k-vecinos mas cercanos. Resultado: 169.951 legitimas vs 169.951 fraudes (50/50).

```
# Resultado SMOTE sobre training set real:
# Antes:   {0: 169.951, 1: 284}  (ratio 598:1)
# Despues: {0: 169.951, 1: 169.951}  (ratio 1:1)
# Muestras sinteticas de fraude generadas: 169.667
# Tamano total del training set tras SMOTE: 339.902
```

Undersampling Aleatorio

Reduce la clase mayoritaria de 169.951 a 284 transacciones legitimas (descartando 169.667, el 99.8% de los datos legitimos).

```
# Resultado Undersampling sobre training set real:
# Antes:   {0: 169.951, 1: 284}
# Despues: {0: 284, 1: 284}  (ratio 1:1)
# Ejemplos legitimos descartados: 169.667 (99.8%)
```

Comparativa Visual

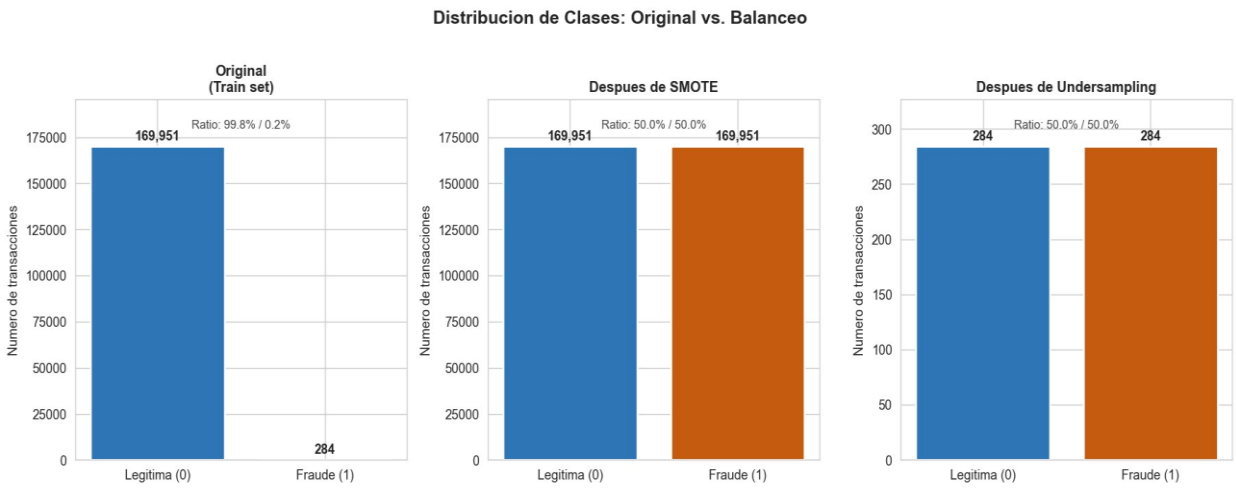

Figura 5: Distribucion real de clases — Original (ratio 598:1), tras SMOTE (50/50) y tras Undersampling (50/50)

Tecnica	Tamano Train Real	Ratio	Ventaja	Riesgo
Original	170.235	599:1	Sin modificacion	Modelo sesgado — predice siempre Legitima
SMOTE	339.902	1:1	Conserva toda la info original + 169.667 sinteticos	Sinteticos pueden no ser completamente realistas
Undersampling	568	1:1	Rapido y simple	Pierde 169.667 transacciones legitimas reales
class_weight	170.235	Sin cambio	No modifica los datos	Puede causar overfitting en la clase fraude

Recomendación para Fase 4 — Modelado

SMOTE es la técnica recomendada como punto de partida. Genera 169.667 ejemplos sintéticos de fraude manteniendo intactos los 169.951 ejemplos legítimos reales. En la Fase 4 se compararán los cuatro enfoques y se seleccionara la combinación modelo + balanceo optima según ROC-AUC y F1-Score sobre el development set.

Datasets Procesados Generados

Archivo	Descripcion	Filas Reales	Columnas
train_scaled.csv	Training set real normalizado (RobustScaler)	170.235	34 (33 feat + Class)
dev_scaled.csv	Development set normalizado	56.745	34 (33 feat + Class)
test_scaled.csv	Test set normalizado — SELLADO hasta Fase 5	56.746	34 (33 feat + Class)
train_smote.csv	Training set con SMOTE (339.902 filas)	339.902	34 (33 feat + Class)
train_undersample.csv	Training set con undersampling (568 filas)	568	34 (33 feat + Class)

Advertencia: Test Set Sellado

El archivo test_scaled.csv (56.746 filas, 95 fraudes reales) NO debe utilizarse hasta la Evaluacion Final (Fase 5). Usarlo antes introduce data leakage y produce estimaciones artificialmente optimistas.

Resumen y Proximos Pasos

Tarea	Estado	Resultado Real
Seleccion y limpieza	Completado	1081 duplicados eliminados. 18.802 outliers Amount conservados. 0 nulos.
Feature Engineering	Completado	Amount_log reduce skewness de 16.98 a 0.16. Is_Night confirma patron nocturno de fraude.
Seleccion de features	Completado	33 features. V17 (r=-0.313), V14 (r=-0.293) y V12 (r=-0.251) las mas discriminantes.
Particion estratificada	Completado	Train 170.235 / Dev 56.745 / Test 56.746. Proporcion fraudes ~0.167% preservada.
Normalizacion	Completado	RobustScaler. Critico: Amount desv.tipica=250 EUR con max=25.691,16 EUR.
Balanceo de clases	Completado	SMOTE genera 169.667 sinteticos. Undersampling descarta 169.667 legitimas.

Fase 4: Modelado — Proximos Pasos

- **Entrenamiento:** XGBoost, LightGBM, Random Forest y MLP sobre train_smote.csv, train_undersample.csv y train_scaled.csv con class_weight.
- **Validacion cruzada:** k=5 folds estratificados sobre training set para estimar rendimiento sin tocar test.
- **Ajuste de hiperparametros:** Grid Search / Bayesian Search sobre development set (56.745 filas, 94 fraudes reales).
- **Seleccion del modelo:** Criterio principal ROC-AUC >= 0.95 y F1-Score (fraude) >= 0.80 sobre development set.
- **Evaluacion final:** Unica pasada sobre test set sellado (56.746 filas, 95 fraudes reales).