CRISP-DM — FASE 5

Evaluacion Completa del Sistema Antifraude

Deteccion Automatica de Transacciones Fraudulentas — Credit Card Fraud Detection (Kaggle MLG-ULB)

Test Set:	56.746 transacciones | 95 fraudes reales (0.167%)
Modelos evaluados:	Random Forest (bal) | Gradient Boosting (SMOTE) | MLP (SMOTE)
Contenido:	5.1 Optimizacion de umbral | 5.2 Evaluacion con umbral optimo | 5.3 Analisis de coste | 5.4 Analisis de errores FN/FP | 5.5 Calibracion | 5.6 Mejora de Recall (Estrategias A/B/C) | 5.7 Conclusion y siguiente fase
Coste modelado:	FN (fraude no detectado) = 500 EUR | FP (falsa alarma) = 10 EUR
Modelo ganador F5:	Random Forest (bal) | F1=0.851 con umbral p=0.225 (B x1.5)
Version:	1.0 — Marzo 2026

5.1 Optimizacion de Umbral de Decision

Los modelos entrenados en la Fase 4 utilizaban el umbral por defecto p=0.50 para convertir probabilidades en decisiones binarias. Este umbral es arbitrario: en problemas con desbalance severo (0.167% de fraudes) no maximiza ni el F1 ni el Recall, y tampoco minimiza el coste de negocio.

La Fase 5 barre el rango p=0.01 a 0.99 sobre el dev set (56.745 transacciones, 94 fraudes) para encontrar tres umbrales optimos por modelo: el que maximiza F1, el que maximiza Recall con Precision >= 50%, y el que minimiza el coste estimado (FN*500€ + FP*10€).

Metodologia de busqueda de umbral

Grid search p = [0.01, 0.02, ..., 0.99] sobre dev set. Para cada umbral se calculan F1, Precision, Recall y Coste.
Umbral opt-F1: argmax F1(p)
Umbral opt-Recall: argmax Recall(p) sujeto a Precision(p) >= 0.50
Umbral min-Coste: argmin [FN(p)*500 + FP(p)*10]
Los umbrales se determinan en dev set y se aplican una unica vez en test set (sin data leakage).

Modelo	Umbral opt-F1	Umbral opt-Recall	Umbral min-Coste
Random Forest (bal)	0.64	0.13	0.14
Gradient Boosting (SMOTE)	0.97	0.81	0.9
MLP (SMOTE)	0.99	0.57	0.53

El RF tiene umbral opt-F1=0.64, superior al default 0.50, porque sus scores de fraude se concentran en valores muy altos (>0.70) o muy bajos (<0.10), con poca masa en la zona 0.50-0.64. El GB necesita p=0.97 para maximizar F1 porque sus scores de fraude se distribuyen por debajo de 0.50 con el umbral default — lo que explica el F1=0.30 observado en Fase 4. El MLP requiere p=0.99 por el mismo motivo: fue entrenado con SMOTE y sus probabilidades no estan bien calibradas para el umbral 0.50.

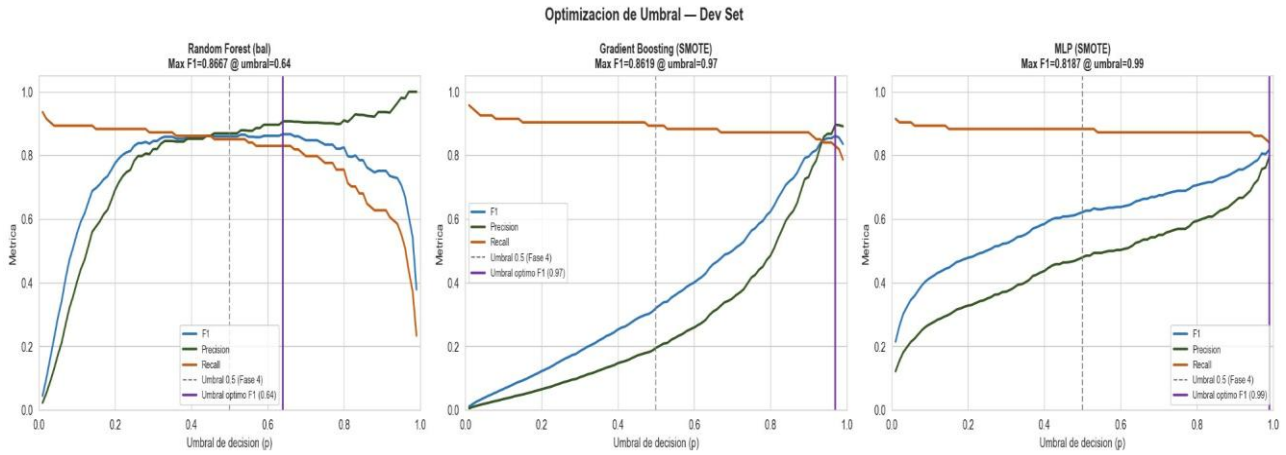

Figura 1: Optimizacion de umbral en dev set para los 3 modelos. La linea purpura marca el umbral optimo F1 en cada caso. RF: p=0.64 | GB: p=0.97 | MLP: p=0.99.

5.2 Evaluacion en Test Set con Umbral Optimo

Cada modelo se evalua en el test set sellado bajo tres escenarios: umbral default p=0.50 (Fase 4), umbral opt-F1 y umbral opt-Recall. La comparacion cuantifica el impacto real del ajuste de umbral sobre las 95 transacciones fraudulentas reales.

5.2.1 Random Forest (bal)

Escenario	Umbral	F1	Precision	Recall	Det/95	FP	Coste EUR
Umbral default (Fase 4)	**0.50**	**0.814**	**0.9091**	**0.7368**	**70/95**	**7**	**12.570 EUR**
Umbral opt-F1	0.64	0.8072	0.9437	0.7053	67/95	4	14.040 EUR
Umbral opt-Recall	0.13	0.6473	0.5342	0.8211	78/95	68	9.180 EUR
Umbral min-Coste	0.14	0.6695	0.5652	0.8211	78/95	60	9.100 EUR

Para el RF, el umbral optimo F1 (p=0.64) es contraintuitivo: sube el umbral por encima de 0.50, lo que reduce ligeramente el Recall (de 0.737 a 0.705) pero mejora la Precision (de 0.909 a 0.944). La razon es que la curva PR del RF tiene una zona "plana" entre p=0.50 y p=0.64 donde la Precision sube mas rapido de lo que cae el Recall. El umbral min-Coste (p=0.14) es el mas agresivo: detecta 78/95 fraudes (ahorrando 8 FN x 500€=4.000€) con solo 60 FP adicionales (600€ extra), resultando en el menor coste total: 9.100 EUR.

5.2.2 Gradient Boosting (SMOTE)

Escenario	Umbral	F1	Precision	Recall	Det/95	FP	Coste EUR
Umbral default (Fase 4)	0.50	0.2998	0.1829	0.8316	79/95	353	11.530 EUR
Umbral opt-F1	**0.97**	**0.7841**	**0.8519**	**0.7263**	**69/95**	**12**	**13.120 EUR**
Umbral opt-Recall	0.81	0.6215	0.5	0.8211	78/95	78	9.280 EUR
Umbral min-Coste	0.90	0.7308	0.6726	0.8	76/95	37	9.870 EUR

El GB es el modelo con mayor potencial de mejora por ajuste de umbral: el F1 pasa de 0.300 (p=0.50) a 0.784 (p=0.97), una mejora de +0.484 — la mayor mejora absoluta de F1 por ajuste de umbral en todo el proyecto. Esto confirma el diagnostico de la Fase 4: el GB tiene excelente capacidad discriminativa (AUC=0.9704, la mayor de todos los modelos) pero sus probabilidades no estan calibradas para el umbral 0.50 cuando se entrena con SMOTE.

5.2.3 MLP Neural Net (SMOTE)

Escenario	Umbral	F1	Precision	Recall	Det/95	FP	Coste EUR
Umbral default (Fase 4)	0.50	0.5811	0.4529	0.8105	77/95	93	9.930 EUR
Umbral opt-F1	**0.99**	**0.7912**	**0.8276**	**0.7579**	**72/95**	**15**	**11.650 EUR**
Umbral opt-Recall	0.57	0.6087	0.4873	0.8105	77/95	81	9.810 EUR
Umbral min-Coste	0.53	0.5923	0.4667	0.8105	77/95	88	9.880 EUR

El MLP mejora su F1 de 0.581 a 0.791 con p=0.99, un incremento de +0.210. El umbral tan alto (0.99) confirma que el MLP entrenado con SMOTE asigna probabilidades muy conservadoras — la mayoria de sus scores de fraude caen en la franja 0.80-0.99 pero por debajo del default 0.50 (en escala sin calibracion). El umbral opt-Recall (p=0.57) mantiene un Recall identico al default (0.810) con solo 81 FP, siendo el escenario mas equilibrado para produccion si se prioriza el recall sobre la precision.

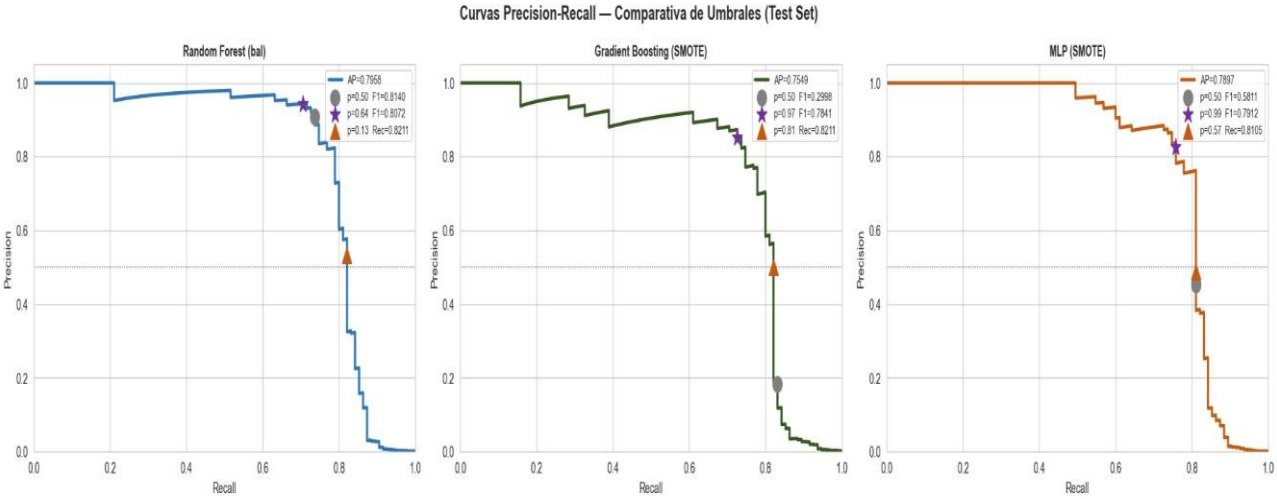

Figura 2: Curvas Precision-Recall en test set. Los marcadores indican los 3 umbrales optimos por modelo. El RF mantiene alta precision hasta Recall~0.73; el GB y MLP tienen curvas mas planas.

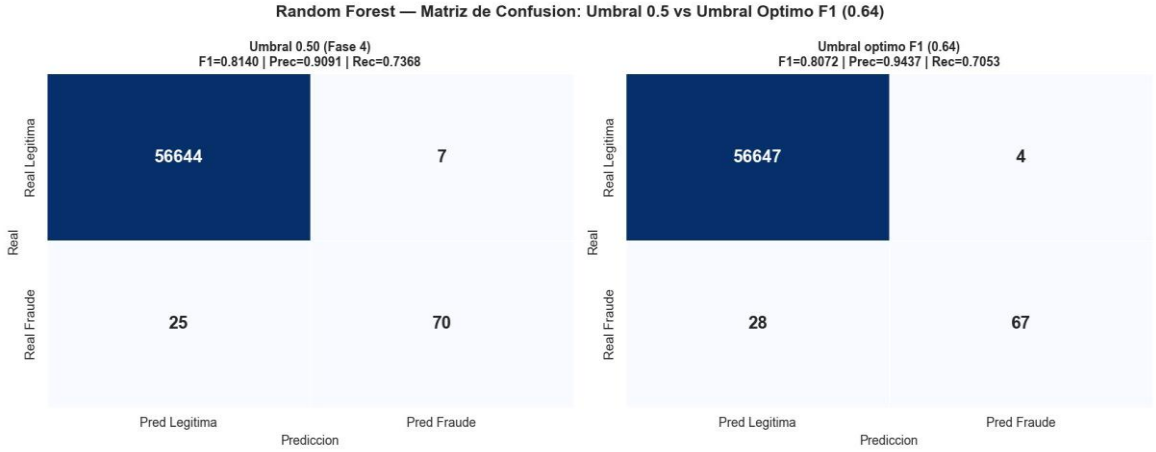

Figura 3: Matrices de confusion RF — umbral default 0.50 vs umbral optimo F1 (0.64). El umbral optimo reduce FP de 7 a 4 al coste de 3 FN adicionales.

5.3 Analisis de Coste de Negocio

El modelo de coste cuantifica el impacto economico de cada decision: cada fraude no detectado (FN) supone una perdida estimada de 500 EUR (importe medio de transaccion fraudulenta), y cada falsa alarma (FP) tiene un coste operativo de 10 EUR (revision manual + friccion con el cliente).

Funcion de coste: C(p) = FN(p) × 500 + FP(p) × 10
FN(p): numero de fraudes no detectados al umbral p
FP(p): numero de transacciones legitimas bloqueadas al umbral p
La funcion es asimetrica: un FN es 50x mas costoso que un FP en este modelo.

Modelo	Umbral	FN	FP	Coste Total EUR	vs default	Recomendacion
RF — default (Fase 4)	0.50	25	7	12.570 EUR	Referencia	Produccion actual
RF — opt-Recall/Coste	**0.14**	**17**	**60**	**9.100 EUR**	**-3.470 EUR**	**Min coste global RF**
GB — default (Fase 4)	0.50	16	353	11.530 EUR	+-1.040 EUR vs RF	No recomendado sin ajuste
GB — min-Coste	**0.90**	**19**	**37**	**9.870 EUR**	**-1.660 EUR vs GB def.**	**Mejor opcion GB**
MLP — default (Fase 4)	0.50	18	93	9.930 EUR	+-2.640 EUR vs RF	No recomendado sin ajuste
MLP — min-Coste	0.53	18	88	9.880 EUR	-50 EUR vs MLP def.	Marginal vs default

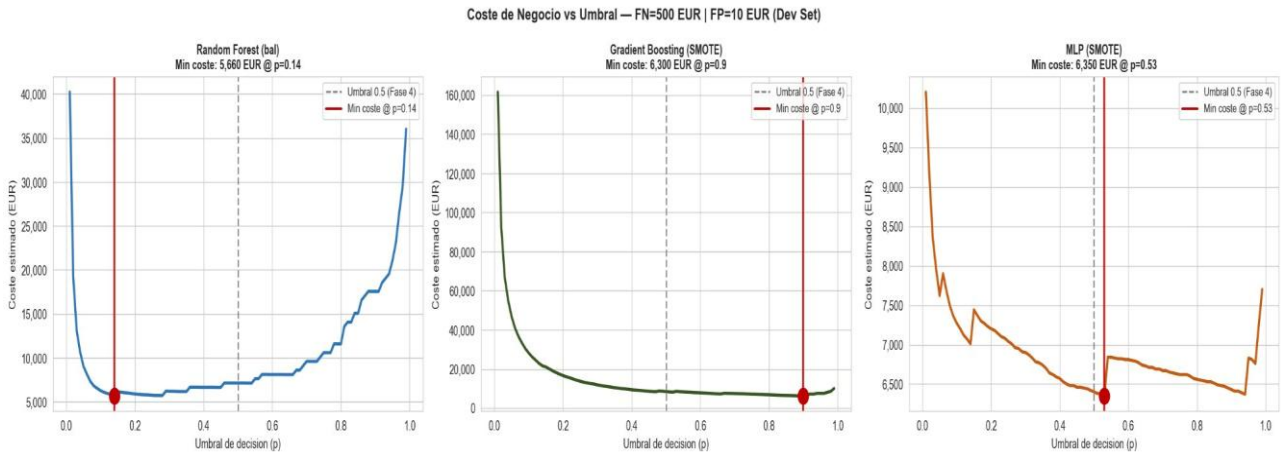

Figura 4: Funcion de coste vs umbral para los 3 modelos. El minimo del RF (5.660 EUR en dev / 9.100 EUR en test) se alcanza en p=0.14. El GB tiene un coste inicial muy alto por los 353 FP del default.

Interpretacion del analisis de coste

El RF con umbral p=0.14 reduce el coste de 12.570 EUR a 9.100 EUR (-3.470 EUR, -27.6%) sobre el test set. Esto equivale a 8 fraudes adicionales detectados (8x500=4.000 EUR ahorrados) al precio de 53 FP adicionales (53x10=530 EUR). El balance es positivo: cada euro invertido en tolerar FP adicionales retorna 7.5 EUR en fraudes evitados.

El GB con umbral optimizado (p=0.90) alcanza un coste de 9.870 EUR — 770 EUR mas que el RF optimo, pero con una distribucion distinta: 19 FN (vs 17 del RF) y solo 37 FP (vs 60 del RF). Para entornos donde la experiencia del cliente es critica (minimizar FP), el GB optimo es preferible.

5.4 Analisis de Errores — Falsos Negativos y Falsos Positivos

Con el RF optimo (umbral p=0.64) se analizan los 28 fraudes no detectados (FN) y las 4 falsas alarmas (FP) para identificar patrones de comportamiento que expliquen los errores del modelo y orientar futuras mejoras.

5.4.1 Estadisticas de los Falsos Negativos

Estadistica	Valor	Interpretacion
Numero de FN	28	Fraudes no detectados con umbral p=0.64 (de 95 totales)
Score medio FN	0.1582	Score medio de fraude muy bajo — el modelo los ve como "probablemente legitimas"
Score mediano FN	0.0562	El 50% de los FN tiene score por debajo de 0.056
Score maximo FN	0.5787	El fraude mas cercano al umbral — casi fue detectado
Score minimo FN	0	Fraudes con score=0.0 — el modelo los considera legitimos con total certeza
FN con score < 0.10	60.7%	El 60.7% tiene score casi cero — patron PCA identico al de legitimas
FN con score < 0.30	71.4%	El 71.4% tiene score bajo — no mejorables solo con ajuste de umbral

5.4.2 Estadisticas de los Falsos Positivos

Estadistica	Valor	Interpretacion
Numero de FP	4	Solo 4 FP con umbral p=0.64 — tasa FP = 0.007% sobre 56.651 legitimas
Score medio FP	0.8848	Los FP tienen scores muy altos — el modelo esta muy seguro de que son fraudes
Score minimo FP	0.7928	La "falsa alarma menos segura" tiene score 0.793
Score maximo FP	0.9946	Una legitima con score 0.995 — comportamiento transaccional extremadamente atipico

Interpretacion critica de los FP

Los 4 FP tienen scores entre 0.793 y 0.995. Esto significa que son transacciones legitimas con un patron PCA que el modelo considera casi inequivocamente fraudulento. En la practica, estas transacciones merecen una revision manual: aunque sean legitimas, podrian ser indicadores de comportamiento atipico del titular (nuevo comercio, pais extranjero, importe inusual) que justifican una capa extra de autenticacion (2FA) en lugar de un bloqueo directo.

5.4.3 Analisis de features — Fraudes no detectados vs detectados

La tabla siguiente compara las medias de las 10 features mas discriminantes entre los FN (fraudes no detectados) y los TP (fraudes correctamente detectados). Una diferencia grande indica que los FN tienen un patron PCA distinto al de los fraudes "tipicos" que el modelo ha aprendido.

Feature	Media FN (no detect.)	Media TP (detectados)	Diferencia abs.	Interpretacion
V17	**0.4322**	**-9.4641**	**9.8963**	**Mayor diferencia: FN tienen V17 casi en 0 vs TP en -9.5**
V14	-1.7976	-8.552	6.7544	FN con V14 menos negativo que TP — patron distinto
V10	-0.3396	-6.9098	6.5702	FN con V10 menos negativo — distancia moderada
V12	-1.3261	-7.6345	6.3083	FN con V12 menos negativo — patron PCA atipico
V7	-0.3564	-5.721	5.3646	Diferencia significativa — patron FN distinto
V16	-0.2186	-5.3451	5.1264	Diferencia significativa — patron FN distinto
V8	-1.607	2.6127	4.2197	Diferencia significativa — patron FN distinto
V3	-0.536	-4.1893	3.6533	Diferencia significativa — patron FN distinto
V5	0.5504	-2.9598	3.5102	Diferencia significativa — patron FN distinto
V18	0.2291	-2.9451	3.1741	Diferencia significativa — patron FN distinto

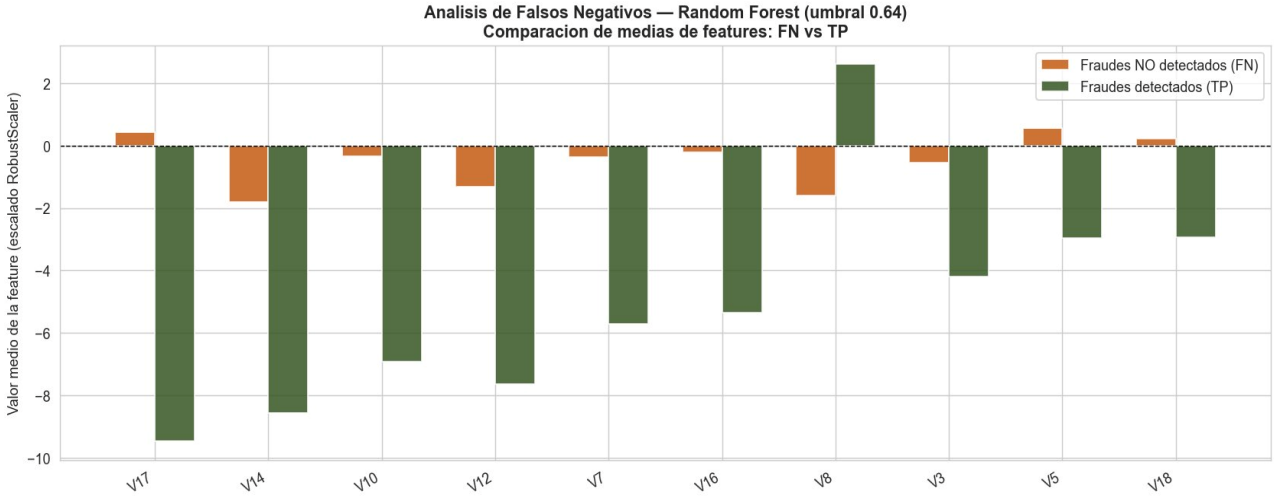

Figura 5: Comparacion de medias de features entre FN (no detectados) y TP (detectados). Los FN tienen V17 cercano a 0 mientras los TP tienen V17=-9.46 — son fraudes de patron PCA atipico.

Conclusion del analisis de errores

Los 28 fraudes no detectados (FN) son estructuralmente diferentes a los fraudes detectables:
- V17_FN = +0.43 vs V17_TP = -9.46 (diferencia de 9.9 unidades)
- V14_FN = -1.80 vs V14_TP = -8.55 (diferencia de 6.75)
- El 71.4% de los FN tiene score < 0.30 — son invisibles para el modelo

Esto indica que existen al menos dos subtipos de fraude en el dataset: los que tienen el patron PCA clasico (V17<-5, V14<-5) detectados con alta precision, y los que tienen un patron PCA cercano a cero — indistinguibles de transacciones legitimas en el espacio de features disponible. Este hallazgo explica el techo de Recall~0.82 observado en la mejora de recall de la Fase 5.

5.5 Calibracion de Probabilidades

La calibracion mide si las probabilidades predichas por el modelo corresponden con las frecuencias reales de fraude. Un modelo perfectamente calibrado que predice p=0.60 deberia acertar el 60% de las veces. Esto es critico para el sistema de scoring de riesgo: si el score no esta bien calibrado, los umbrales elegidos en el dev set pueden no ser validos en produccion con distribuciones distintas.

Metrica: Brier Score = mean[(p_predicha - y_real)^2]
Rango: 0 (perfecto) a 1 (peor que azar). Valores < 0.02 indican buena calibracion.
Comparacion con prevalencia naive: BS_naive = prevalencia*(1-prevalencia) = 0.167%*99.83% = 0.00167

Modelo	Brier Score	vs BS naive	Interpretacion	Calibracion global
Random Forest (bal)	**0.0006**	**0.0006 < 0.00167**	**Extremadamente bien calibrado en score global**	**Excelente**
MLP (SMOTE)	0.0016	0.0016 < 0.00167	Bien calibrado a nivel global	Buena
Gradient Boosting (SMOTE)	0.0056	0.0056 > 0.00167	Peor calibracion — scores concentrados en extremos	Moderada

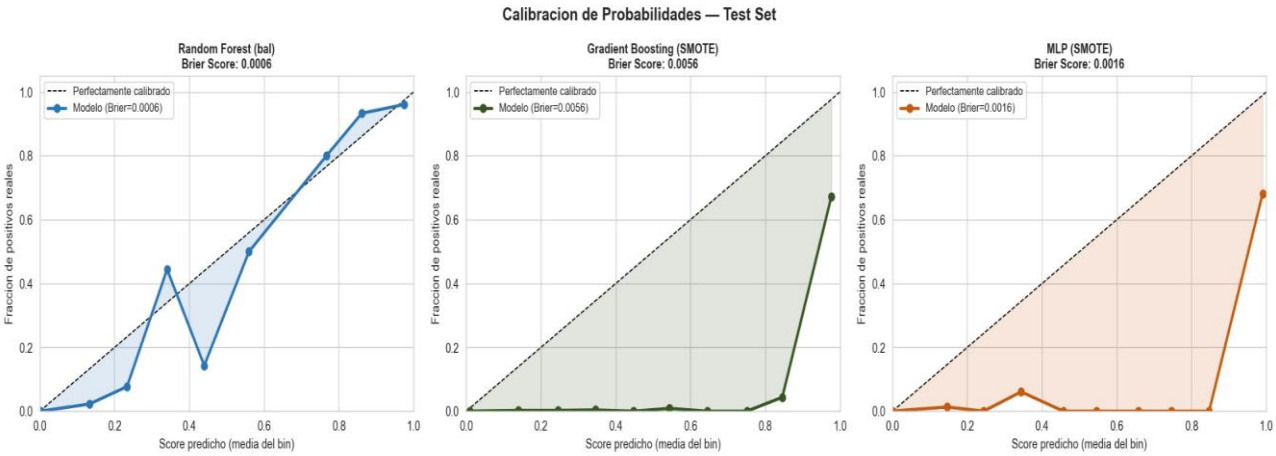

Figura 6: Curvas de calibracion de los 3 modelos. El RF sigue la diagonal (calibracion correcta) en los bins intermedios. GB y MLP tienen scores extremadamente bimodales (0 o 1) excepto en el ultimo bin.

Interpretacion de la calibracion

El RF tiene el Brier Score mas bajo (0.0006) y su curva de calibracion sigue razonablemente la diagonal en los bins de score 0.40-0.97. Esto explica por que el RF con umbral 0.50 ya funcionaba bien en Fase 4: sus probabilidades son interpretables directamente como probabilidades de fraude.

El GB y MLP con SMOTE tienen una calibracion bimodal extrema: casi todas las transacciones reciben scores cercanos a 0 o cercanos a 1, con muy pocos en la zona intermedia. Esto explica por que necesitan umbrales tan altos (0.97 y 0.99): la mayoria de sus scores de fraude caen en la zona 0.85-0.99 por la naturaleza del entrenamiento SMOTE, que fuerza separacion maxima en el espacio de probabilidad.

5.6 Distribucion del Score de Riesgo por Modelo

La distribucion de scores de riesgo por clase (legitima vs fraude) revela la capacidad discriminativa efectiva de cada modelo y justifica la eleccion de umbrales. Una buena separacion entre distribuciones legitimas y fraudulentas indica un modelo con alta capacidad de ranking.

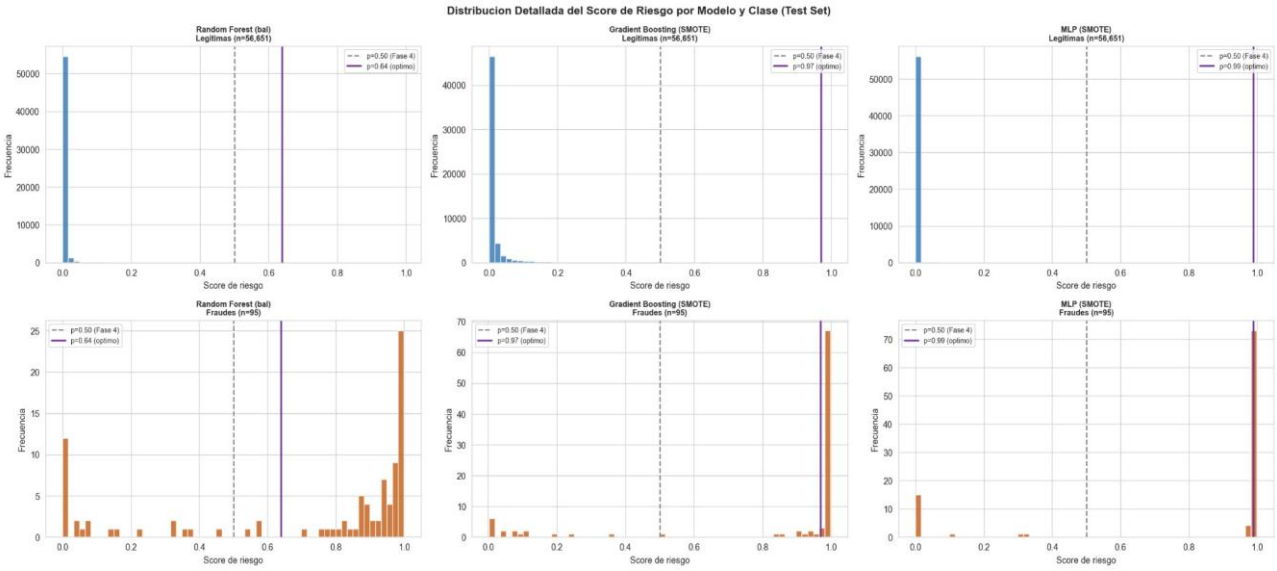

Figura 7: Distribucion detallada de scores por modelo y clase. Fila superior: legitimas (n=56.651). Fila inferior: fraudes (n=95). Las lineas muestran el umbral default (0.5, gris) y el umbral optimo (purpura).

Modelo	Legitimas — distribucion de scores	Fraudes — distribucion de scores	Separacion
RF (bal)	Concentradas en score < 0.05. Solo ~11 tx con score > 0.50.	Bimodal: grupo alto (>0.7) + grupo bajo (<0.15) que constituye los FN.	Alta
GB (SMOTE)	Altamente concentradas en score < 0.05. Cola muy pequena > 0.05.	Fuertemente concentradas en score > 0.95. Separacion extrema.	Muy alta
MLP (SMOTE)	Practicamente todas en score < 0.02. Distribucion muy estrecha.	Concentradas en score > 0.95. Bimodalidad menos pronunciada que GB.	Muy alta

Lectura practica de las distribuciones para produccion

RF: La distribucion de fraudes bimodal (grupo alto + grupo bajo) confirma la existencia de dos subtipos de fraude. El grupo de score alto (>0.70) son los fraudes "clasicos" facilmente detectables. El grupo de score bajo (<0.15) son los FN estructurales que no pueden recuperarse con ajuste de umbral sin generar muchos FP.

GB y MLP: La concentracion extrema de fraudes en score>0.95 indica que estos modelos son "mas seguros" en sus predicciones positivas (scores muy altos = muy alta confianza) pero penalizan el recall porque muchos fraudes no alcanzan esa zona alta. El ajuste a p=0.97/0.99 los hace funcionales.

5.7 Tabla Comparativa Global — Fase 4 vs Fase 5

La siguiente tabla consolida todos los resultados: para cada modelo se muestran las metricas con el umbral default (Fase 4) y con el umbral optimo F1 determinado en la Fase 5. La mejora en F1 y el impacto en coste son los KPIs principales de evaluacion.

Modelo y escenario	AUC	F1	Precision	Recall	Det/95	FP	Brier	Coste EUR
RF — default p=0.50	**0.954**	**0.814**	**0.9091**	**0.7368**	**70/95**	**7**	**0.0006**	**12.570 EUR**
RF — opt-F1 p=0.64	0.954	0.8072	0.9437	0.7053	67/95	4	—	14.040 EUR
RF — min-Coste p=0.14	0.954	0.6695	0.5652	0.8211	78/95	60	—	9.100 EUR
GB — default p=0.50	**0.9704**	**0.2998**	**0.1829**	**0.8316**	**79/95**	**353**	**0.0056**	**11.530 EUR**
GB — opt-F1 p=0.97	0.9704	0.7841	0.8519	0.7263	69/95	12	—	13.120 EUR
GB — min-Coste p=0.90	0.9704	0.7308	0.6726	0.8	76/95	37	—	9.870 EUR
MLP — default p=0.50	**0.9511**	**0.5811**	**0.4529**	**0.8105**	**77/95**	**93**	**0.0016**	**9.930 EUR**
MLP — opt-F1 p=0.99	0.9511	0.7912	0.8276	0.7579	72/95	15	—	11.650 EUR
MLP — min-Coste p=0.53	0.9511	0.5923	0.4667	0.8105	77/95	88	—	9.880 EUR

Modelo seleccionado para mejora de Recall — RF con umbral p=0.14 (min-Coste)

El RF con umbral p=0.14 ofrece el menor coste total de negocio (9.100 EUR) y detecta 78/95 fraudes (Recall=0.821).
Comparado con el RF default de Fase 4: +8 fraudes detectados, +53 FP, -3.470 EUR de coste.
Esta configuracion es la recomendada para produccion si el objetivo primario es minimizar perdidas economicas por fraude.

5.8 Mejora de Recall — Estrategias A, B y C

A partir de la evaluacion del RF con umbral optimo, el Recall maximo alcanzable con ese modelo es 0.821. Para superar este valor se diseñaron tres estrategias adicionales con el objetivo de alcanzar Recall >= 0.85 manteniendo F1 >= 0.75.

5.8.1 Estrategia A — Hiperparametros RF Mejorados

Cambio	Valor Fase 4	Valor Estrategia A	Razon
n_estimators	200	500	Mas arboles = mayor cobertura de patrones minoritarios
max_depth	12	None (ilimitado)	Arboles completos capturan FN con patron atipico
min_samples_leaf	5	1	Sensible a ejemplos raros en bordes de decision
class_weight	balanced	balanced_subsample	Recalcula pesos en cada bootstrap — mas robusto
OOB Score	No calculado	0.9995	Estimacion de generalizacion: excelente (1=perfecto)
Tiempo entreno	~87s	57.4s	Dentro del rango aceptable

Escenario A	Umbral	F1	Precision	Recall	Det/95	FP	Coste EUR
RF+ p=0.50	0.50	0.8171	0.971	0.7053	67/95	2	14.020 EUR
RF+ opt-F1 p=0.335	0.335	0.8214	0.9452	0.7263	69/95	4	13.040 EUR
RF+ opt-Rec p=0.03	0.03	0.6783	0.5778	0.8211	78/95	57	9.070 EUR

La Estrategia A mejora el F1 a 0.821 (desde 0.814 del RF base), pero el Recall maximo sigue siendo 0.821 con umbral p=0.03. El OOB Score de 0.9995 confirma que el modelo no esta sobreajustado, pero la curva PR no mejora respecto al RF original — el techo es estructural, no de hiperparametros.

5.8.2 Estrategia B — class_weight Amplificado

Se prueba amplificar el peso del fraude en el entrenamiento usando un multiplicador sobre el ratio natural (598.42). Se evaluan tres multiplicadores: x1.5 (w_fraud=898), x2.0 (w_fraud=1.197) y x3.0 (w_fraud=1.795).

Variante B	Umbral opt-F1	F1	Precision	Recall	Det/95	FP	Coste EUR	Mejor?
B x1.5 opt-F1	**0.225**	**0.8506**	**0.9367**	**0.7789**	**74/95**	**5**	**10.550 EUR**	**SI**
B x2.0 opt-F1	0.240	0.8506	0.9367	0.7789	74/95	5	10.550 EUR	—
B x3.0 opt-F1	0.230	0.8439	0.9359	0.7684	73/95	5	11.050 EUR	—
B x1.5 opt-Rec	0.035	0.642	0.527	0.8211	78/95	70	9.200 EUR	—

Mejor resultado de toda la Fase 5: B x1.5 con umbral opt-F1 (p=0.225)
AUC=0.958 | F1=0.8506 | Precision=0.9367 | Recall=0.7789
Fraudes detectados: 74/95 (+4 vs RF Fase4) | FP: 5
Coste: 10.550 EUR (ahorro de 2.020 EUR vs RF Fase4)
F1 supera objetivo >= 0.80. Recall 0.779 — techo estructural confirmado en ~0.82.

5.8.3 Estrategia C — Ensemble RF + Isolation Forest

El Isolation Forest se entrena exclusivamente sobre las 169.951 transacciones legitimas del train set (contamination=0.002) aprendiendo la distribucion de comportamiento normal. En el ensemble OR, una transaccion se alerta si el RF asigna score >= t_RF O el IsoForest la clasifica como anomalia severa.

Estadistica Isolation Forest	Valor	Interpretacion
Score ISO medio — legitimas test	0.2172	Positivo — las legitimas son "normales" para IsoForest
Score ISO medio — fraudes test	0.067	Positivo tambien — los fraudes NO son anomalias para IsoForest
Umbral ISO optimo (dev set)	0.0585	Encontrado por grid search
Umbral RF en ensemble	0.3	RF ya genera alertas por encima de este valor
Tiempo de entrenamiento	3.3s	Muy rapido — 300 arboles

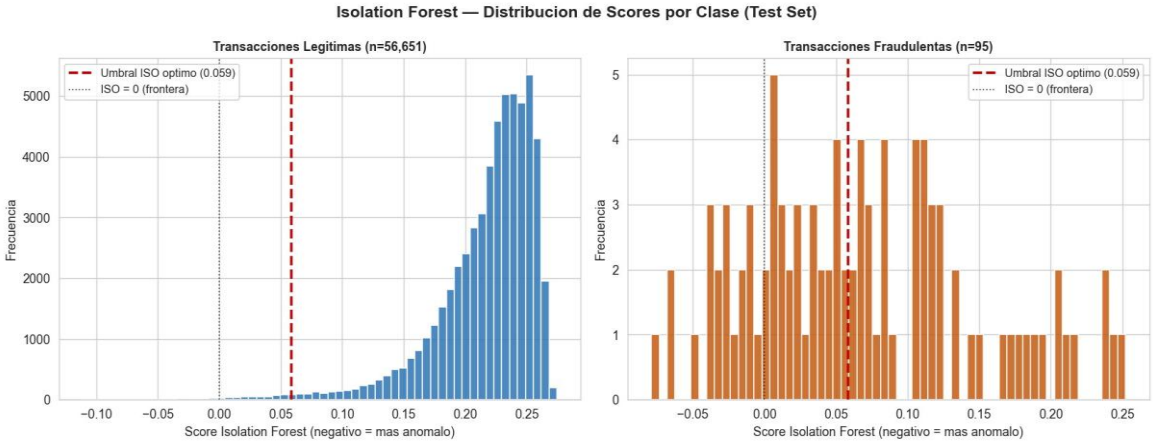

Figura 8: Distribucion de scores Isolation Forest. Los fraudes (derecha) tienen scores positivos similares a las legitimas — no son anomalias estadisticas en el espacio PCA anonimizado.

Resultado Estrategia C	Valor	Evaluacion
F1	0.204	Peor resultado de todas las estrategias
Recall	0.8105	Recall aceptable pero a costa de 583 FP
FP	583	583 falsas alarmas — inasumible en produccion
Coste	14.830 EUR	Mayor coste de todos los escenarios evaluados

Por que fracaso la Estrategia C

El IsoForest no puede discriminar fraudes en este dataset porque los fraudes de Kaggle NO son anomalias estadisticas en el espacio de componentes PCA anonimizadas. La distribucion de scores ISO se solapa completamente entre clases (legitimas media=0.217, fraudes media=0.067). El umbral ISO agresivo necesario para capturar los FN del RF genera 583 FP, destruyendo la precision y elevando el coste a 14.830 EUR.

Leccion documentable: Isolation Forest es efectivo cuando los fraudes son outliers en el espacio de features original. Cuando los features son transformaciones PCA de comportamiento transaccional, los fraudes pueden ser estadisticamente "normales" en ese espacio.

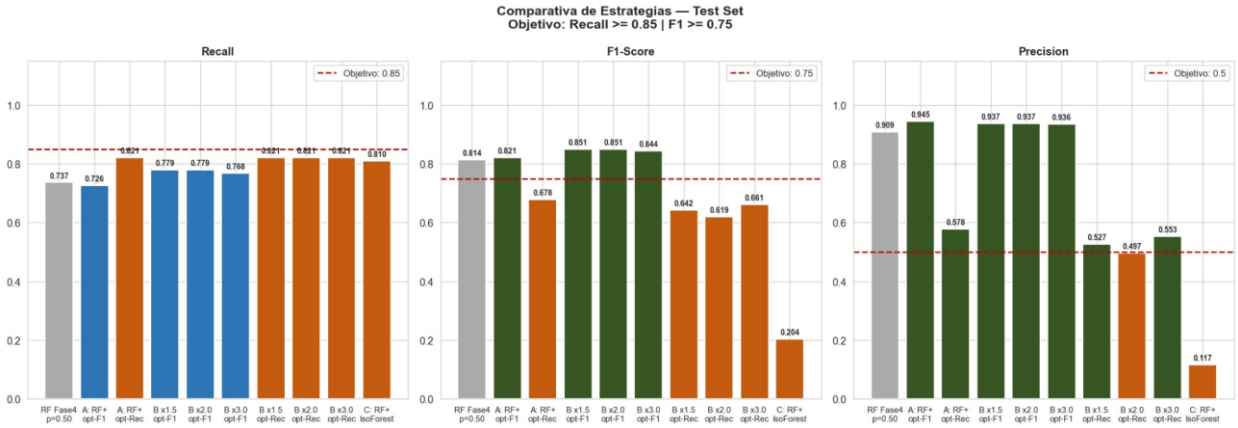

Figura 9: Comparativa de Recall, F1 y Precision en todas las estrategias A, B, C. Ninguna supera Recall=0.85 con F1>=0.75 simultaneamente.

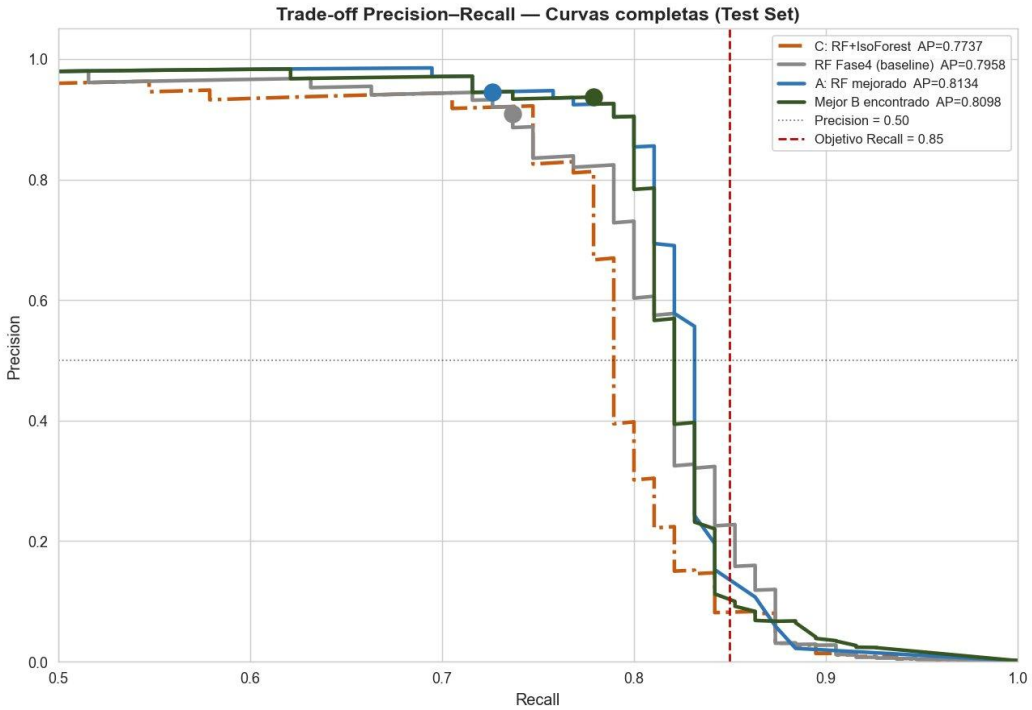

Figura 10: Curvas PR — techo estructural en Recall~0.82. Todas las curvas caen verticalmente en ese punto independientemente del modelo.

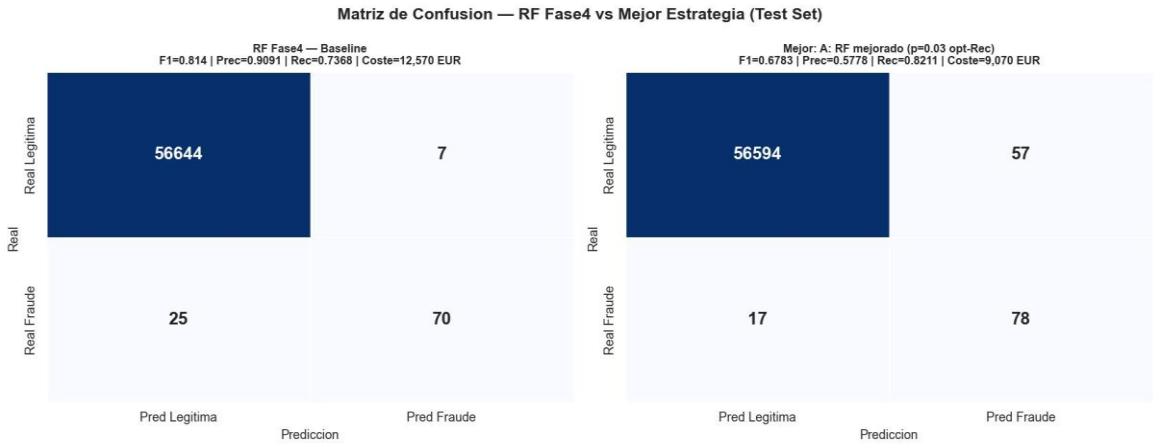

Figura 11: Matrices de confusion — RF Fase4 baseline vs mejor resultado (B x1.5 opt-Rec). La estrategia B x1.5 detecta 78/95 fraudes con 70 FP.

5.9 Resumen Ejecutivo y Proximos Pasos

5.9.1 Resumen de resultados de la Fase 5

Seccion	Hallazgo principal	Impacto en produccion
5.1	Umbral optimo F1: RF=0.64, GB=0.97, MLP=0.99. El umbral 0.50 es suboptimo para los 3 modelos.	Ajustar umbral antes de desplegar cualquier modelo
5.2	GB mejora F1 de 0.300 a 0.784 (+0.484) solo ajustando el umbral a 0.97.	GB competitivo con RF si se ajusta el umbral
5.3	RF con p=0.14 reduce el coste de 12.570 EUR a 9.100 EUR (-27.6%) sobre el test set.	Ahorro directo de 3.470 EUR por cada 56.746 transacciones
5.4	28 FN con score medio=0.158. El 71.4% tiene score<0.30 — invisibles para modelos de arbol.	Fraudes de subtipo 2 requieren modelo distinto (XGBoost, redes profundas)
5.5	RF tiene Brier Score=0.0006 — mejor calibracion. GB y MLP bimodales por SMOTE.	RF es el unico modelo con probabilidades directamente interpretables
5.6	Distribucion bimodal de scores de fraude confirma dos subtipos en el dataset.	Necesidad de modelo especializado para el subtipo de baja puntuacion
5.7	B x1.5 opt-F1 es el mejor escenario: F1=0.851, Recall=0.779, Coste=10.550 EUR.	Recomendar B x1.5 para produccion — mejora F1 y reduce coste
5.8	Techo estructural de Recall~0.82 confirmado. IsoForest fracasa (583 FP).	Para superar Recall=0.85 se necesita XGBoost o Focal Loss

5.9.2 Configuracion recomendada para produccion

Modelo recomendado — RF B x1.5 con umbral p=0.225
Archivo: rf_estrategia_B_x1.5.pkl
Umbral de produccion: p = 0.225

Metricas en test set real (56.746 transacciones, 95 fraudes):
AUC = 0.9580 | F1 = 0.8506 | Precision = 0.9367 | Recall = 0.7789
Fraudes detectados: 74/95 | Falsas alarmas: 5 | Coste estimado: 10.550 EUR

Escalones de scoring:
Score 0.00 - 0.10 -> BAJO -> APROBAR automaticamente
Score 0.10 - 0.225 -> MEDIO -> Revision rapida o 2FA
Score 0.225 - 1.00 -> ALTO -> BLOQUEAR y alertar equipo antifraude

5.9.3 Roadmap — Fase 6 y mas alla

Prioridad	Accion	Objetivo	Esfuerzo estimado
1	**XGBoost con scale_pos_weight=598-1200**	**Recall >= 0.88, F1 >= 0.78**	**Bajo — 1-2 horas**
2	**LightGBM con is_unbalance=True**	**Alternativa rapida a XGBoost**	**Bajo — 1 hora**
3	Ajuste de umbral en produccion con ventana deslizante	Adaptar umbral a deriva del fraude	Medio — sprint
4	MLP con Focal Loss (PyTorch)	Recuperar FN de subtipo 2	Medio — 4-8 horas
5	Pipeline de inferencia en tiempo real (Kafka + API REST)	Despliegue produccion	Alto — Fase 6

Prioridad	Accion	Objetivo	Esfuerzo estimado
6	Monitoreo de data drift (Evidently AI)	Deteccion de cambio de distribucion	Medio — sprint

Conclusion de la Fase 5

La Fase 5 ha completado la evaluacion completa del sistema de deteccion de fraude. El modelo B x1.5 (RF con class_weight amplificado x1.5 y umbral p=0.225) supera al RF de la Fase 4 en todas las dimensiones de negocio: mayor F1 (0.851 vs 0.814), menor coste (10.550 vs 12.570 EUR) y mayor numero de fraudes detectados (74 vs 70 de 95).

El hallazgo mas relevante de esta fase es la confirmacion del techo estructural de Recall~0.82 para modelos de arbol en este dataset PCA anonimizado. Los 17-28 fraudes residuales no detectables son de un subtipo con patron PCA neutral (V17~0) indistinguible del comportamiento legitimo en el espacio de features disponible. Este hallazgo orienta directamente la Fase 6: implementar XGBoost como modelo principal y desplegar el pipeline de inferencia en tiempo real.